

Máster Universitario en Computación y Sistemas Inteligentes

Konputazioari eta Sistema Adimendunei buruzko Unibertsitate Masterra

Proyecto fin de máster

Master amaierako proiektua

Implementación y análisis comparativo de algoritmos clásicos y computación cuántica híbrida para la optimización de carteras de inversión bajo restricciones de cardinalidad

Aimar Etxaniz Urbiet

Director/a: Aitor Moreno Fernandez

Bilbao, septiembre de 2026



Deusto

Facultad de Ingeniería
Ingeniaritza Fakultatea

Máster Universitario en Computación y Sistemas Inteligentes

Konputazioari eta Sistema Adimendunei buruzko Unibertsitate Masterra

Proyecto fin de máster

Master amaierako proiektua

Implementación y análisis comparativo de algoritmos clásicos y computación cuántica híbrida para la optimización de carteras de inversión bajo restricciones de cardinalidad

Aimar Etxaniz Urbiet

Director/a: Aitor Moreno Fernandez

Bilbao, septiembre de 2026

A stylized, handwritten signature in blue ink.

Resumen

La selección de carteras de inversión bajo restricciones realistas, como la cardinalidad exacta de activos, es un problema de optimización combinatoria cuya complejidad crece de forma exponencial con el número de activos disponibles, lo que limita severamente la capacidad de los métodos exactos clásicos para resolverlo a gran escala. La computación cuántica, y en particular el Algoritmo de Optimización Cuántica Aproximada (QAOA), se ha propuesto como una vía prometedora para abordar este tipo de problemas, aunque su formulación estándar presenta una limitación relevante: la imposición de restricciones mediante penalizaciones en la función de coste no garantiza que las soluciones obtenidas sean siempre factibles.

Este proyecto diseña, implementa y evalúa experimentalmente una variante de QAOA –el XY-QAOA– que incorpora la restricción de cardinalidad directamente en la dinámica del circuito cuántico, mediante una inicialización en estados de Dickey y un operador mezclador restringido de tipo XY , evitando así el uso de penalizaciones. Se complementa esta arquitectura con un esquema de inicialización de parámetros basado en optimización adiabática troterizada (TQA) y un mecanismo opcional de regularización del bucle de optimización clásico. El algoritmo se implementa en simulación clásica sobre datos financieros reales y se compara sistemáticamente frente a un solucionador exacto (Gurobi) y una metaheurística clásica de referencia (Simulated Annealing), con el fin de caracterizar en qué medida esta arquitectura resuelve el problema de factibilidad del QAOA estándar y cuál es su viabilidad práctica en el contexto tecnológico actual.

Descriptores

Computación Cuántica, Optimización de carteras, QAOA, Mezclador XY, Finanzas

Índice general

1. Introducción	1
1.1. Motivación y Contexto de la Optimización Financiera	1
1.1.1. El problema de la selección de carteras	1
1.1.2. La dimensionalidad combinatoria	1
1.1.3. Impacto industrial	2
1.2. Cuántica en el Sector Financiero	2
1.2.1. Iniciativas corporativas	2
1.3. La Computación Cuántica NISQ en Finanzas	3
1.3.1. Límites de la computación clásica	3
1.3.2. Computación cuántica híbrida	3
1.3.3. QAOA (Quantum Approximate Optimization Algorithm)	3
1.3.4. Contribuciones del Trabajo	4
1.4. Estructura de la Memoria	5
2. Objetivos, Alcance y Antecedentes	6
2.1. Objetivos del proyecto	6
2.1.1. Objetivo General	6
2.1.2. Objetivos Específicos	6
2.1.3. Hipótesis de Trabajo	7
2.2. Alcance	8
2.2.1. Dentro del Alcance	8
2.2.2. Fuera del Alcance	9
2.3. Antecedentes y estado del arte	9
2.3.1. De Markowitz al problema combinatorio	9
2.3.2. Solucionadores clásicos de referencia	10
2.3.3. Computación cuántica variacional	10

2.3.4.	Limitaciones documentadas del QAOA estándar	11
2.3.5.	Trabajos relacionados: mezcladores XY, inicialización TQA y QAOA en carteras	11
2.4.	Posicionamiento del trabajo	12
3.	Plan de Trabajo y Presupuesto	14
3.1.	Fases del Proyecto	14
3.1.1.	Desglose Horario	15
3.2.	Planificación Temporal	18
3.2.1.	Cronograma	18
3.3.	Presupuesto y Plan de Financiación	19
3.3.1.	Costes de Personal	19
3.3.2.	Otros Costes	19
3.3.3.	Presupuesto Total	20
4.	Marco Teórico	21
4.1.	Introducción	21
4.2.	Formulación Matemática	21
4.2.1.	El Modelo Continuo de Media-Varianza	21
4.2.2.	Formulación QUBO	22
4.2.3.	Mapeo al Hamiltoniano de Ising	23
4.3.	Arquitectura Cuántica	24
4.3.1.	QAOA Estándar y el Mezclador Transversal	24
4.3.2.	Deformación del Paisaje y Barren Plateaus	24
4.3.3.	Estados de Dicke y Confinamiento Combinatorio	25
4.3.4.	El Operador de Mezcla XY	27
4.4.	Estabilización del Paisaje de Optimización Clásica	28
4.4.1.	Trotterized Quantum Annealing (TQA)	28
4.4.2.	Regularización Ridge L_2	29
5.	Desarrollo del Proyecto y Diseño Experimental	31
5.1.	Introducción	31
5.2.	Recopilación y preparación de datos	31
5.2.1.	Fuente de los datos	31
5.2.2.	Regímenes de mercado	32
5.2.3.	Cálculo de retornos y de la matriz de covarianza	32

5.2.4.	División In-Sample / Out-of-Sample	33
5.2.5.	Selección de subconjuntos de N activos	33
5.3.	Arquitectura del software	34
5.3.1.	Organización de módulos	34
5.3.2.	El simulador de vector de estado	34
5.3.3.	El bucle variacional	35
5.3.4.	Solvers de referencia	36
5.4.	Diseño experimental y calibración de hiperparámetros	36
5.4.1.	Métricas experimentales	37
5.4.2.	Estructura del experimento: dos fases	37
5.4.3.	Presupuesto de iteraciones de COBYLA	38
5.4.4.	Calibración empírica de restarts, α y jitter: estudios piloto	38
5.4.5.	Escalado en N : análisis de coste computacional	42
5.5.	Gestión del presupuesto computacional	42
5.6.	Verificación y reproducibilidad	43
5.7.	Generación del dataset experimental	44
6.	Evaluación y Análisis de Resultados	45
6.1.	Introducción y metodología de análisis	45
6.2.	Gap de optimización frente al tamaño del problema (N)	45
6.3.	Robustez financiera: Ratio de Sharpe fuera de muestra	47
6.4.	Coste temporal y escalabilidad	48
6.5.	Factibilidad estructural de las soluciones	50
6.6.	Efecto de la profundidad del circuito (p)	51
6.7.	Limitaciones estadísticas	52
7.	Valoración Ética	54
7.1.	Principios de la Ética	54
7.1.1.	Honestidad y Rigor Científico	54
7.1.2.	Transparencia	54
7.2.	Impacto Ambiental y Sostenibilidad	55
7.2.1.	Huella de Carbono de la Cuántica Clásica	55
7.2.2.	Eficiencia Energética	55
7.3.	Brecha Tecnológica Cuántica	55

8. Conclusiones y Trabajo Futuro	57
8.1. Conclusiones Generales	57
8.2. Grado de Cumplimiento de los Objetivos e Hipótesis	58
8.2.1. Contraste de las Hipótesis de Trabajo	58
8.3. Limitaciones del Trabajo	59
8.4. Líneas Futuras de Trabajo	60
Bibliografía	62
A. Declaración de Uso de Inteligencia Artificial	64

Índice de figuras

2.1. Diagrama de flujo del bucle de optimización híbrido clásico-cuántico variacional (QAOA). . . .	11
3.1. Estructura de Descomposición del Trabajo del proyecto.	16
3.2. Diagrama de Gantt.	18
4.1. Diagrama de flujo conceptual del mapeo matemático	23
4.2. Representación conceptual del impacto de la varianza del gradiente en algoritmos variacionales.	25
4.3. Representación conceptual de la reducción de la dimensionalidad combinatoria.	26
4.4. Comparación geométrica sobre el hipercubo booleano de $N = 3$ cúbits con cardinalidad $K = 1$: el QAOA estándar (izquierda) recorre los ocho vértices, seis infactibles; el XY-QAOA (derecha) se limita al triángulo de los tres vértices factibles.	28
4.5. Topología general del circuito cuántico XY-QAOA: inicialización determinista en el estado de Dicke, seguida por la aplicación iterativa de los operadores de coste $U_C(\gamma)$ y los operadores de mezcla con preservación de peso de Hamming $U_M^{XY}(\beta)$	29
4.6. Efecto analítico de la regularización Ridge L_2 en el paisaje de energía de la función de coste. (Conceptual)	30
5.1. Optimization GAP medio con y sin regularización Ridge, por tamaño de universo N . Los intervalos representan la desviación estándar entre semillas. Datos: <code>output/results/alpha_ablation.csv</code>	40
5.2. Tiempo de ejecución con y sin regularización Ridge, por tamaño de universo N	41
6.1. Optimization GAP medio (%) frente al tamaño de universo N , para Simulated Annealing, Standard QAOA y XY-QAOA Regularizado ($p = 3, 1$ restart, 12 semillas por punto)	46
6.2. Ratio de Sharpe medio frente a N : Gurobi In-Sample, Gurobi Out-of-Sample y XY-QAOA Regularizado Out-of-Sample.	47
6.3. Tiempo de ejecución medio (s, escala logarítmica) frente a N , para Gurobi, Simulated Annealing, Standard QAOA y XY-QAOA Regularizado.	48

6.4. Tasa de factibilidad media (%) frente a N : Standard QAOA frente a XY-QAOA. Las bandas sombreadas representan ± 1 desviación estándar entre 12 semillas.	50
6.5. Efecto de la profundidad del circuito p sobre el Optimization GAP (izquierda) y el tiempo de ejecución (derecha), con $N = 14$ fijo. Standard QAOA frente a XY-QAOA Regularizado.	51
6.6. Reducción de Varianza Inter-Semilla del GAP de Optimización.	52

Índice de cuadros

1.1. Dimensión del espacio de soluciones según la formulación matemática y el confinamiento del espacio de estados.	4
2.1. Comparativa del estado del arte en algoritmos de optimización combinatoria clásica y cuántica.	13
3.1. Desglose detallado de dedicación horaria por paquete de trabajo y tarea (Total: 200 h).	17
3.2. Presupuesto financiero consolidado del proyecto de investigación.	20
4.1. Comparativa analítica entre el mezclador transversal (X) y el mezclador de intercambio (XY).	27
5.1. Ablación de la regularización Ridge: Optimization GAP medio (%) $\pm$ desviación estándar entre 5 semillas, con y sin el término Ridge activo ($p = 3$).	40
5.2. Tiempo de ejecución medio de una llamada completa al solver variacional, en función de N (con $p = 3$ fijo). Promedio sobre Standard QAOA y XY-QAOA Regularized, 12 semillas por punto.	42
6.1. Tiempo de ejecución medio (s) por solver y tamaño de universo N ($p = 3$).	49

1. INTRODUCCIÓN

La gestión cuantitativa de activos financieros constituye uno de los pilares fundamentales de la economía de mercado contemporánea. En este capítulo, se contextualiza el problema de la selección de carteras óptimas desde la perspectiva de la Teoría Moderna de Carteras (MPT) clásica, identificando las barreras computacionales que surgen de forma natural al aproximar los modelos matemáticos a las restricciones operativas reales de los mercados. Asimismo, se introduce la computación cuántica híbrida en la era del ruido intermedio (NISQ) como un nuevo paradigma computacional disruptivo que motiva el desarrollo de este trabajo.

1.1. MOTIVACIÓN Y CONTEXTO DE LA OPTIMIZACIÓN FINANCIERA

1.1.1. El problema de la selección de carteras

El origen de la asignación cuantitativa de activos está en el modelo de media-varianza de Markowitz (1952) [1]. Este enfoque transformó la construcción de carteras de inversión en un problema formal de optimización matemática biobjetivo, donde las decisiones se fundamentan en el equilibrio analítico entre el retorno esperado (maximización del rendimiento) y el riesgo de mercado (minimización de la varianza de los activos). Bajo este marco conceptual, la frontera eficiente delimita el conjunto de carteras óptimas que ofrecen el máximo rendimiento posible para un nivel de riesgo determinado, o equivalentemente, el mínimo riesgo para un retorno objetivo.

1.1.2. La dimensionalidad combinatoria

A pesar de la elegancia analítica del modelo original de Markowitz, su aplicabilidad directa en la industria financiera está severamente limitada debido a que asume un mercado continuo y libre de fricciones. En escenarios operativos reales, las entidades financieras deben incorporar restricciones de carácter discreto esenciales para cumplir con las directrices regulatorias, las políticas de gestión de riesgos y la viabilidad comercial.

La introducción de restricciones duras, tales como la cardinalidad exacta K (que fija el número estricto de activos permitidos en la composición de la cartera), los lotes mínimos de contratación o los costes de transacción fijos por apertura de posiciones, altera drásticamente la naturaleza analítica del problema, trasladándolo desde una clase de complejidad computacional eficientemente resoluble hacia una clase de problemas combinatorios de coste exponencial en el peor caso. Esta transición, conocida como la maldición de la dimensionalidad

combinatoria, constituye el reto computacional central que aborda este trabajo, y su formalización precisa en términos de la teoría de la complejidad computacional se desarrolla en la Sección 2.3.1 del siguiente capítulo.

1.1.3. Impacto industrial

Para las firmas de gestión de activos, fondos de cobertura (*hedge funds*) y banca de inversión, la incapacidad de resolver estos modelos combinatorios en universos masivos de activos implica una pérdida directa de eficiencia analítica. El arbitraje de mercado y la volatilidad sistémica exigen la toma de decisiones óptimas o cuasi-óptimas en ventanas de tiempo operativas críticamente estrechas. La dependencia actual de aproximaciones heurísticas clásicas que no garantizan la convergencia ni la calidad de la solución motiva la búsqueda de alternativas tecnológicas capaces de procesar estructuras combinatorias densas de forma eficiente.

1.2. CUÁNTICA EN EL SECTOR FINANCIERO

1.2.1. Iniciativas corporativas

La exploración de algoritmos cuánticos e híbridos para la optimización de carteras ha dejado de ser un campo puramente teórico, convirtiéndose en un área de inversión estratégica para la banca global. Instituciones como JPMorgan Chase y Goldman Sachs han liderado el desarrollo de metodologías variacionales aplicadas a la gestión de activos y a la valoración de derivados complejos mediante técnicas de amplitud cuántica, colaborando activamente con consorcios como IBM Quantum Network [2, 3].

En el ámbito europeo y nacional, el sector bancario ha mostrado un dinamismo notable en la ejecución de pruebas de concepto (PoC). CaixaBank, en colaboración con instituciones del ecosistema de supercomputación, implementó con éxito modelos híbridos para la selección de carteras con restricciones de inversión, demostrando que las arquitecturas variacionales pueden estructurar el riesgo en mercados altamente correlacionados de forma competitiva [4].

Por su parte, el banco BBVA ha desarrollado líneas de investigación paralelas enfocadas en la optimización de carteras complejas mediante técnicas de recocido cuántico (*Quantum Annealing*) y algoritmos basados en compuertas para la era NISQ [5], determinando que la codificación óptima de restricciones financieras en Hamiltonianos de espín es una competencia crítica para la futura resiliencia operativa del sector [6]. Asimismo, el Banco Santander ha llevado a cabo proyectos piloto orientados a la gestión de riesgos globales y al arbitraje de divisas, consolidando la necesidad de formar perfiles profesionales capaces de orquestar flujos de trabajo

híbridos en la nube.

1.3. LA COMPUTACIÓN CUÁNTICA NISQ EN FINANZAS

1.3.1. Límites de la computación clásica

Los solucionadores exactos deterministas tradicionales, de uso extendido en la industria financiera, experimentan una degradación exponencial de su rendimiento temporal a medida que el universo disponible de activos candidatos N escala de forma moderada ($N \gg 100$) bajo restricciones de cardinalidad estricta K . La exploración sistemática del subespacio factible se vuelve inabordable clásicamente, forzando a la industria a sacrificar el rigor analítico de la solución global en favor de la rapidez operativa de las heurísticas de búsqueda local. El funcionamiento concreto de estos solucionadores de referencia se describe en la Sección 2.3.2.

1.3.2. Computación cuántica híbrida

La computación cuántica emerge como una alternativa disruptiva sustentada en los principios de la mecánica cuántica, tales como la superposición, la interferencia cuántica y el entrelazamiento. No obstante, los dispositivos actuales pertenecen a la era NISQ (*Noisy Intermediate-Scale Quantum*), caracterizada por procesadores de escala intermedia (decenas o cientos de cúbits) que carecen de tolerancia a fallos debido a la ausencia de corrección de errores cuánticos y a los efectos de la decoherencia ambiental [7].

Para operar de forma robusta en este escenario restrictivo, se justifica metodológicamente el empleo de algoritmos cuánticos híbridos variacionales. Este enfoque establece un paradigma de co-procesamiento en el cual la Unidad de Procesamiento Cuántico (QPU) se limita a la preparación y medición de estados cuánticos entrelazados mediante circuitos de baja profundidad (minimizando el impacto del ruido), mientras que una Unidad de Procesamiento Central (CPU) clásica ejecuta el bucle de optimización de los parámetros del circuito utilizando algoritmos variacionales libres de gradiente (como COBYLA o Nelder-Mead).

1.3.3. QAOA (Quantum Approximate Optimization Algorithm)

Dentro de los algoritmos híbridos para optimización combinatoria, el Algoritmo de Optimización Cuántica Aproximada (QAOA), introducido originalmente por Farhi, Goldstone y Gutmann [8], destaca por su analogía con la computación cuántica adiabática y se erige como el algoritmo de referencia sobre el que se construye la

propuesta de este trabajo. Su funcionamiento general, su representación esquemática y sus limitaciones documentadas en la literatura se desarrollan en detalle en la Sección 2.3.3 del siguiente capítulo, mientras que su formalización matemática completa —incluyendo la definición de los operadores $U_C(\gamma)$ y $U_M(\beta)$ y la arquitectura con preservación de simetría propuesta en este trabajo— se presenta íntegramente en el Capítulo 4.

El impacto analítico de esta preservación de simetría se evidencia cuantitativamente al evaluar la escala de reducción del espacio de estados factible frente al espacio completo para diferentes dimensiones del universo de activos N bajo una restricción de cardinalidad constante, tal como se desglosa en la Tabla 1.1.

Cuadro 1.1.: Dimensión del espacio de soluciones según la formulación matemática y el confinamiento del espacio de estados.

Universo (N)	Cardinalidad (K)	Espacio Completo (2^N)	Subespacio Factible ($\binom{N}{K}$)	Reducción del Espacio (%)
10	5	1.024	252	75,39 %
12	5	4.096	792	80,66 %
14	5	16.384	2.002	87,78 %
16	5	65.536	4.368	93,33 %
20	10	1.048.576	184.756	82,38 %

1.3.4. Contribuciones del Trabajo

Este trabajo aporta tres contribuciones diferenciadas:

- **C1 (Algorítmica).** Diseño e implementación de un *ansatz constraint-preserving* para la selección de carteiras con cardinalidad exacta, combinando inicialización en estado de Dicke, mezclador XY e inicialización TQA de los parámetros variacionales.
- **C2 (Experimental).** Benchmarking sistemático y reproducible del XY-QAOA regularizado frente a Standard QAOA, Simulated Annealing y Gurobi sobre datos reales de mercado, con escalado en N y en p , y evaluación conjunta de factibilidad, GAP, coste temporal y Sharpe OOS.
- **C3 (Metodológica).** Estudio de ablación de TQA y de la regularización Ridge L_2 que aísla la contribución real de cada componente, mostrando de forma honesta que la mejora observada procede principalmente del confinamiento estructural del subespacio factible, y no de la penalización Ridge L_2 , ni —bajo el diseño experimental empleado— en una ventaja de calidad de solución frente a los solucionadores clásicos de referencia.

1.4. ESTRUCTURA DE LA MEMORIA

El presente documento técnico está estructurado en nueve capítulos y un anexo interconectados sobre todo el ciclo de investigación, desarrollo y validación del proyecto:

- **Capítulo 1: Introducción.** Expone la motivación financiera y la delimitación de las fronteras computacionales de la optimización combinatoria clásica que justifica la exploración de alternativas cuánticas.
- **Capítulo 2: Objetivos, alcance y antecedentes.** Define los objetivos generales y específicos que guían la investigación, delimita el alcance computacional del software desarrollado y establece el estado del arte detallado en finanzas cuánticas.
- **Capítulo 3: Plan de trabajo, estructura de proyecto y presupuesto.** Desarrolla la vertiente de gestión de proyectos mediante el desglose de tareas, el cronograma detallado de ejecución y el análisis de costes del proyecto.
- **Capítulo 4: Marco teórico.** Formaliza matemáticamente el mapeo del problema financiero a un Hamiltoniano de Ising y la arquitectura del circuito XY-QAOA con preservación de simetría.
- **Capítulo 5: Desarrollo del proyecto / Memoria técnica.** Detalla la recopilación y preparación de los datos, el diseño experimental y la ejecución concreta del marco experimental.
- **Capítulo 6: Evaluación y análisis de resultados.** Presenta y discute los resultados empíricos obtenidos, contrastándolos frente a los solucionadores de referencia clásicos.
- **Capítulo 7: Valoración ética del proyecto.** Evalúa de forma sistemática los impactos éticos, sociales y ambientales de la tecnología desarrollada.
- **Capítulo 8: Conclusiones y trabajo futuro.** Valora el grado de cumplimiento de los objetivos planteados, recoge las limitaciones del trabajo y traza las líneas de investigación futura.
- **Capítulo 9: Bibliografía.** Recopilación exhaustiva de las fuentes bibliográficas que sustentan científicamente el desarrollo del proyecto, siguiendo el estándar IEEE adaptado por la Universidad de Deusto.
- **Anexos**

2. OBJETIVOS, ALCANCE Y ANTECEDENTES

2.1. OBJETIVOS DEL PROYECTO

2.1.1. Objetivo General

El objetivo principal consiste en evaluar la viabilidad técnica, la robustez matemática y la competitividad financiera de los algoritmos cuánticos híbridos variacionales frente a los métodos clásicos de optimización en la resolución del problema de selección de carteras sujeto a restricciones discretas duras de cardinalidad exacta (K).

Con este propósito, la investigación busca determinar en qué medida el confinamiento geométrico del espacio de búsqueda y la estabilización del bucle variacional permiten superar las ineficiencias del paradigma estándar de penalizaciones cuadráticas, estableciendo de forma cuantitativa las capacidades y fronteras de escalabilidad de la computación cuántica en su estado actual frente a los estándares de la industria financiera.

2.1.2. Objetivos Específicos

Para dar cumplimiento estructurado y medible al objetivo general, se establecen los siguientes objetivos específicos:

- **OE1. Verificar la equivalencia matemática del mapeo Markowitz $\rightarrow$ QUBO $\rightarrow$ Ising.** Comprobar que la energía del Hamiltoniano de Ising construido reproduce exactamente la función objetivo financiera original (media-varianza con penalización de cardinalidad) para el conjunto completo de configuraciones binarias en instancias de tamaño reducido ($N \leq 14$), empleando un solucionador exacto por fuerza bruta como referencia de verificación. *Criterio de éxito:* discrepancia numérica nula (dentro de la tolerancia de precisión de punto flotante) entre la energía de Ising y el valor QUBO en el 100 % de las configuraciones evaluadas.
- **OE2. Cuantificar la mejora en la factibilidad estructural de las soluciones cuánticas.** Determinar si la sustitución del mezclador transversal (X -Mixer) y la penalización cuadrática por un operador de intercambio XY inicializado en un estado de Dicke incrementa de forma sustancial la proporción de muestras que satisfacen la restricción $\sum_i x_i = K$, frente al QAOA estándar, para un conjunto de instancias con

$N \in [6, 20]$ y profundidades p acotadas. *Criterio de éxito*: diferencia estadísticamente relevante y creciente con N entre la tasa de factibilidad de ambos enfoques, verificable mediante el muestreo directo del vector de estado simulado.

- **OE3. Evaluar el efecto estabilizador de la inicialización TQA y la regularización Ridge L_2 sobre la convergencia clásica.** Medir si la combinación de una inicialización basada en *Trotterized Quantum Annealing* y una penalización continua L_2 sobre la trayectoria de los parámetros (γ, β) reduce la variabilidad del resultado final del optimizador COBYLA y/o el número de evaluaciones de la función de coste necesarias para alcanzar un óptimo local estable, en comparación con una inicialización aleatoria sin regularizar, sobre una instancia de referencia fija. *Criterio de éxito*: reducción observable de la desviación estándar del *Optimization GAP* entre semillas aleatorias al introducir la regularización.
- **OE4. Contrastar el rendimiento del XY-QAOA regularizado frente a solucionadores de referencia clásicos.** Comparar el *Optimization GAP* respecto al óptimo exacto (Gurobi), el Ratio de Sharpe fuera de muestra y el coste temporal de ejecución del XY-QAOA regularizado frente a Gurobi Optimizer y Simulated Annealing, utilizando series históricas reales de mercado, para determinar el rango de tamaños de universo N en el que la propuesta cuántica resulta competitiva bajo simulación clásica exacta. *Criterio de éxito*: identificación explícita del umbral de N a partir del cual el coste de simulación deja de ser práctico, y caracterización cuantitativa de la relación GAP–robustez financiera en el rango accesible.

2.1.3. Hipótesis de Trabajo

A partir del problema planteado, del análisis del estado del arte y de las limitaciones documentadas en las formulaciones estándar de QAOA para problemas combinatorios con restricciones, se establecen las siguientes hipótesis de trabajo, que guían el diseño experimental del proyecto y que se contrastan explícitamente en la Sección 8.2 del Capítulo 8:

- **H1.** La incorporación explícita de la restricción de cardinalidad en la propia dinámica del circuito (inicialización en estado de Dicke + mezclador XY) produce una tasa de factibilidad estructural superior a la del QAOA estándar con penalización cuadrática, y esta ventaja se acentúa a medida que crece N .
- **H2.** Una inicialización de los parámetros variacionales basada en *Trotterized Quantum Annealing* (TQA) proporciona un punto de partida más informado que una inicialización aleatoria, reduciendo la variabilidad entre semillas del resultado final del optimizador clásico.

- **H3.** La incorporación de una penalización continua Ridge L_2 sobre la trayectoria de los parámetros aporta, de forma aislada, una mejora adicional y consistente sobre la estabilidad o calidad de la solución respecto a usar únicamente inicialización TQA.
- **H4.** Un XY-QAOA regularizado, evaluado bajo simulación clásica exacta y un único reinicio por semilla, alcanza una calidad de solución (GAP de optimización) y una robustez financiera fuera de muestra (Sharpe OOS) competitivas frente a solucionadores clásicos de referencia –el óptimo exacto (Gurobi) y una metaheurística estocástica simple (Simulated Annealing).
- **H5.** Para una profundidad de circuito p fija, el ansatz XY-QAOA agota su capacidad de representación al crecer N , lo que se traduce en un repunte del GAP en las instancias de mayor tamaño estudiadas.

Estas hipótesis no se plantean como resultados asumidos de antemano, sino como proposiciones que se contrastan mediante el diseño experimental descrito en el Capítulo 5 y los resultados del Capítulo 6. El grado de confirmación de cada una se resume explícitamente en la Sección 8.2.

2.2. ALCANCE

El alcance del proyecto constituye un marco fundamental para comprender su propósito, los requerimientos técnicos identificados y los límites operacionales del estudio, estableciendo unas expectativas claras sobre los objetivos abordados.

2.2.1. Dentro del Alcance

El alcance propuesto incluye los siguientes puntos:

- Revisión de la literatura y del estado del arte en algoritmos cuánticos híbridos variacionales aplicados a problemas de optimización combinatoria en finanzas.
- Recopilación, limpieza y preprocesamiento de series temporales de datos históricos reales procedentes de mercados organizados (activos del S&P 500 e IBEX 35).
- Formulación matemática del problema de selección de carteras bajo restricción dura de cardinalidad exacta (K) y su mapeo a estructuras QUBO y Hamiltonianos de espín de Ising.

- Desarrollo e implementación de la simulación cuántica variacional utilizando circuitos con preservación de simetría estructural (estados de Dicke y operador mezclador XY) sobre el framework Qrisp.
- Refinamiento del modelo e hiperparametrización del bucle híbrido variacional, integrando inicialización adiabática troterizada (TQA) y regularización continua Ridge L_2 .
- Evaluación experimental y benchmarking sistemático de las soluciones obtenidas frente a solucionadores clásicos deterministas de grado industrial (Gurobi Optimizer) y metaheurísticas clásicas (Simulated Annealing).

2.2.2. Fuera del Alcance

En este sentido, se define formalmente lo que queda fuera del alcance de este trabajo:

- La ejecución directa en hardware u ordenadores cuánticos reales (QPUs), limitando la experimentación a la simulación matemática clásica exacta mediante vectores de estado.
- La simulación de universos de activos con cardinalidad y dimensión muy elevadas ($N > 20$), debido a la barrera exponencial en los requisitos de memoria RAM y tiempos de cómputo de la simulación clásica.
- El desarrollo de modelos dinámicos multiperiodo con rebalanceo continuo y costes de transacción por deslizamiento (el estudio se enfoca en la asignación estática en un único periodo).
- La integración y procesamiento de flujos de datos de cotización en tiempo real o estrategias de negociación de alta frecuencia (HFT).
- La implementación de esquemas activos de corrección de errores cuánticos (QEC).

2.3. ANTECEDENTES Y ESTADO DEL ARTE

2.3.1. De Markowitz al problema combinatorio

Como se ha introducido en el Capítulo 1, la incorporación de la restricción de cardinalidad exacta K traslada el modelo de Markowitz desde la clase de complejidad P hacia la clase NP-hard, con un espacio de búsqueda discreto gobernado por el coeficiente binomial $\binom{N}{K}$ frente al espacio completo 2^N , tal como se cuantificó en

la Tabla 1.1. Ante este reto computacional, la industria financiera recurre tradicionalmente a dos familias de solucionadores clásicos, cuyas fortalezas y limitaciones se resumen a continuación.

2.3.2. Solucionadores clásicos de referencia

En la práctica cuantitativa actual, la resolución de modelos MIQP de selección de carteras se fundamenta en dos aproximaciones complementarias:

- **Solucionadores Deterministas Exactos (Gurobi Optimizer)** [9]: certifican la optimalidad global de la solución mediante planos de corte y bifurcación ramificada, al coste de un escalado temporal exponencial en el peor caso.
- **Metaheurísticas Estocásticas (Simulated Annealing)**: algoritmos de búsqueda local inspirados en el recocido de materiales, rápidos y escalables, pero sin certificado de convergencia global ni garantía de reproducibilidad exacta entre semillas pseudoaleatorias.

2.3.3. Computación cuántica variacional

La incapacidad de los métodos clásicos deterministas para mitigar el crecimiento combinatorio en universos densos impulsó el interés por la computación cuántica. Históricamente, las primeras aproximaciones prácticas se desarrollaron sobre plataformas analógicas de recocido cuántico (*Quantum Annealing*), diseñadas para minimizar funciones de energía mediante tunelamiento cuántico en redes de espines físicos. No obstante, las restricciones de conectividad en los grafos de acoplamiento físico y la susceptibilidad al ruido ambiental motivaron la transición hacia el paradigma cuántico digital basado en compuertas lógicas parametrizadas.

En este marco digital de la era NISQ [7], el Algoritmo de Optimización Cuántica Aproximada (QAOA), introducido por Farhi et al. [8], se posicionó como el referente fundamental para optimización combinatoria. QAOA opera alternando la aplicación de operadores unitarios parametrizados por ángulos (γ, β) correspondientes a un Hamiltoniano de coste (que codifica la función objetivo) y un Hamiltoniano mezclador transversal (*X-Mixer*). En la formulación estándar, la observancia de restricciones duras como la cardinalidad K se gestiona mediante términos de penalización cuadrática integrados en la función de coste, mapeando el problema a un formato de Optimización Binaria Cuadrática No Restrictiva (QUBO).

El flujo general del algoritmo híbrido variacional se ilustra en la Figura 2.1.




Figura 2.1.: Diagrama de flujo del bucle de optimización híbrido clásico-cuántico variacional (QAOA).

2.3.4. Limitaciones documentadas del QAOA estándar

El QAOA estándar con penalizaciones presenta dos limitaciones estructurales ampliamente documentadas en la literatura especializada cuando se aplica a problemas fuertemente restringidos: (i) la deformación del paisaje energético inducida por multiplicadores de penalización de gran magnitud, y (ii) el fenómeno de mesetas estériles o *Barren Plateaus*, por el cual la varianza del gradiente de la función de coste se desvanece con el número de cúbits del registro [10]. El mecanismo formal de ambas patologías, así como la arquitectura propuesta en este trabajo para superarlas, se desarrolla en detalle en la Sección 4.3.2 del Capítulo 4.

2.3.5. Trabajos relacionados: mezcladores XY, inicialización TQA y QAOA en carteras

La restricción del espacio de búsqueda mediante mezcladores que preservan el peso de Hamming fue formalizada dentro del marco general del *Quantum Alternating Operator Ansatz*, y su aplicación específica a mezcladores *XY* inicializados en estados de Dicke ha sido validada tanto en simulación como en hardware real de trampa de iones por He et al. [11], quienes muestran que la alineación entre el estado inicial y el mezclador mejora sistemáticamente el rendimiento de QAOA en problemas con restricciones. Niroula et al. [12] aplican un enfoque análogo a un problema de resumen extractivo, confirmando la generalidad de esta familia de mezcladores más allá de las finanzas. Brandhofer et al. [13] realizan un *benchmarking* sistemático de QAOA aplicado a optimización de carteras, comparando distintas formulaciones, tamaños de universo y estrategias de penalización frente a solucionadores clásicos, en línea metodológica con el enfoque comparativo adoptado en este trabajo.

Frente al trabajo de Mancilla et al. [14] –la propuesta más cercana en la literatura–, este TFM aporta una caracterización experimental más sistemática del punto de ruptura entre viabilidad estructural y competitividad en calidad de solución, en lugar de limitarse a un único escenario de mercado favorable.

El trabajo más directamente comparable a esta propuesta es el de Mancilla et al. [14], quienes combinan igualmente inicialización en estado de Dicke, mezclador *XY* e inicialización troterizada de tipo adiabático para la

selección de carteras bajo restricción de cardinalidad, evaluando su enfoque mediante *backtesting* sobre datos reales de mercado. A diferencia de dicho trabajo, que reporta una ventaja de Sharpe Ratio del enfoque cuántico frente a Simulated Annealing en un backtest de *walk-forward* sobre 10 activos con una única ventana temporal, este TFM evalúa el comportamiento del algoritmo bajo un barrido sistemático de tamaño de universo ($N = 6$ a $N = 20$) y de profundidad de circuito, y bajo el régimen de un único reinicio por semilla —más representativo del coste de ejecución en hardware NISQ real que el mejor de varios reinicios—, lo que permite caracterizar de forma más granular el punto exacto en el que la ventaja de factibilidad estructural del enfoque cuántico se traduce, o no, en una ventaja de calidad de solución frente a una metaheurística clásica simple.

Por último, la estrategia de inicialización basada en *Trotterized Quantum Annealing* adoptada en la Sección 4.4 del Capítulo 4 tiene su origen en el trabajo de Sack y Serbyn [15], quienes demuestran que esta inicialización permite evitar mínimos falsos en el paisaje de optimización de QAOA para un amplio rango de pasos temporales de Trotter, con un rendimiento comparable al mejor resultado obtenido tras un número exponencialmente creciente de inicializaciones aleatorias.

2.4. POSICIONAMIENTO DEL TRABAJO

Frente a las limitaciones documentadas del QAOA estándar y la ineficiencia de evaluar el espacio completo de Hilbert 2^N , este trabajo adopta un enfoque de diseño algorítmico avanzado. En lugar de sancionar las soluciones no factibles mediante penalizaciones algebraicas externas, se restringe la dinámica física del circuito cuántico al subespacio geométrico estricto de las carteras válidas $\binom{N}{K}$, complementando dicha estructura con un esquema bicapa de inicialización adiabática guiada (TQA) y regularización Ridge L_2 en el optimizador clásico.

La Tabla 2.1 sintetiza la comparativa taxonómica entre los diferentes paradigmas de optimización clásica y cuántica analizados en este estado del arte, posicionando conceptualmente la arquitectura propuesta dentro del panorama tecnológico contemporáneo.

Cuadro 2.1.: Comparativa del estado del arte en algoritmos de optimización combinatoria clásica y cuántica.

Algoritmo / Enfoque	Paradigma de Computación	Manejo de Restricciones (K)	Eficiencia en Cúbits / Recursos	Escalabilidad en la Era NISQ
Gurobi Optimizer [9]	Clásico Determinista Exacto	Planos de corte y bifurcación ramificada.	Memoria RAM y CPU con escalado exponencial en peor caso.	Nula para instancias densas de gran escala ($N \gg 100$).
Simulated Annealing	Clásico Estocástico Heurístico	Penalización o rechazo analítico de vecinos.	Cómputo CPU secuencial ligero y altamente paralelizable.	Alta rapidez temporal, pero sin certificado de optimalidad global.
Standard QAOA [8]	Cuántico Digital Variacional	Penalización cuadrática en la función de coste (QUBO).	Requiere N cúbits sin registros auxiliares.	Baja (alta sensibilidad a mesetas estériles e inestabilidad por penalización).
Quantum Annealing	Cuántico Adiabático Nativo	Mapeo de penalizaciones QUBO en grafos físicos.	Alta dependencia del grafo de acoplamiento del chip.	Media (condicionada por la conectividad limitada del hardware).
XY-QAOA Regularizado (Propuesto)	Cuántico Híbrido Variacional	Confinamiento físico en subespacio combinatorio reducido.	Optimizado a N cúbits lineales libres de registros auxiliares.	Alta (menor profundidad de circuito y mayor resistencia al ruido físico [16]).

3. PLAN DE TRABAJO Y PRESUPUESTO

3.1. FASES DEL PROYECTO

Para garantizar un control del alcance, el proyecto se ha estructurado en cinco Paquetes de Trabajo secuenciales, desglosados en tareas:

1. 1: Gestión y Revisión Bibliográfica

- *T1.1. Revisión del estado del arte en QAOA y computación NISQ:* Análisis crítico de la literatura sobre algoritmos variacionales, mesetas estériles (*Barren Plateaus*), Hamiltonianos de Ising y preservación de simetría.
- *T1.2. Delimitación y modelado del problema financiero:* Formalización del problema de selección de carteras de Markowitz con restricción dura de cardinalidad exacta K y análisis de su complejidad combinatoria NP-hard.

2. 2: Modelado Matemático y Formulación

- *T2.1. Construcción del modelo QUBO y calibración de penalizaciones:* Mapeo algebraico de la función objetivo.
- *T2.2. Derivación del Hamiltoniano de Ising y subespacio de Dicke:* Transformación afín de variables binarias a operadores de espín de Pauli Z_i , acoplamientos J_{ij} , campos locales h_i y demostración analítica de la conmutación del operador XY-Mixer.

3. 3: Desarrollo de Software

- *T3.1. Pipeline de datos de mercado y preprocesado financiero:* Implementación de la ingesta automatizada desde Yahoo Finance, cálculo de retornos logarítmicos continuos, matrices de covarianza anualizadas y división temporal *In-Sample* / *Out-of-Sample*.
- *T3.2. Implementación de estados de Dicke y transpilación del XY-Mixer:* Programación en el framework Qrisp del circuito determinista de preparación del estado de Dicke $|D_K^N\rangle$ y síntesis del mezclador XY sobre topología de acoplamiento lineal y en anillo.

- *T3.3. Esquema de regularización bicapa TQA y Ridge L_2* : Desarrollo de la clase `RegularizedQA0AProblem` para calcular ángulos de inicio adiabáticos (TQA) e integrar la penalización continua cuadrática en el optimizador clásico COBYLA.
- *T3.4. Integración de solvers clásicos de referencia y verificación del software*: Implementación de la interfaz con Gurobi Optimizer (*Branch-and-Bound*) y Simulated Annealing (`dwave-neal`), declaración de `pytest` como dependencia de verificación y desarrollo del script de comprobación por fuerza bruta del mapeo QUBO–Ising descrito en la Sección 5.6.

4. 4: Experimentación, Simulación y Benchmarking

- *T4.1. Ejecución de simulaciones variacionales*: Ejecución de las instancias parametrizadas en escalado dimensional y barrido de profundidad del ansatz.
- *T4.2. Recopilación de métricas y evaluación comparativa*: Procesamiento de los datos de convergencia, cálculo del Optimization GAP, tasa de factibilidad matemática, Ratio de Sharpe OOS y análisis del coste temporal en CPU.

5. 5: Redacción de la Memoria

- *T5.1. Estructuración y redacción técnica de capítulos en LaTeX*: Redacción exhaustiva y rigurosa de la memoria técnica conforme a los estándares académicos del máster.
- *T5.2. Generación automatizada de gráficos vectoriales y tablas*: Desarrollo de scripts en Python (`matplotlib/seaborn`) para la renderización de figuras analíticas en alta resolución (300 DPI) y cuadros comparativos.
- *T5.3. Control de calidad, revisión ortotipográfica*: Verificación de coherencia metodológica entre objetivos y conclusiones, maquetación final y elaboración del soporte visual para la defensa.

La Figura 3.1 ilustra la disposición jerárquica de la Estructura de Descomposición del Trabajo descrita.

3.1.1. Desglose Horario

El Cuadro 3.1 detalla la distribución exacta de las 200 horas de dedicación efectiva entre los cinco paquetes de trabajo y sus tareas asociadas.

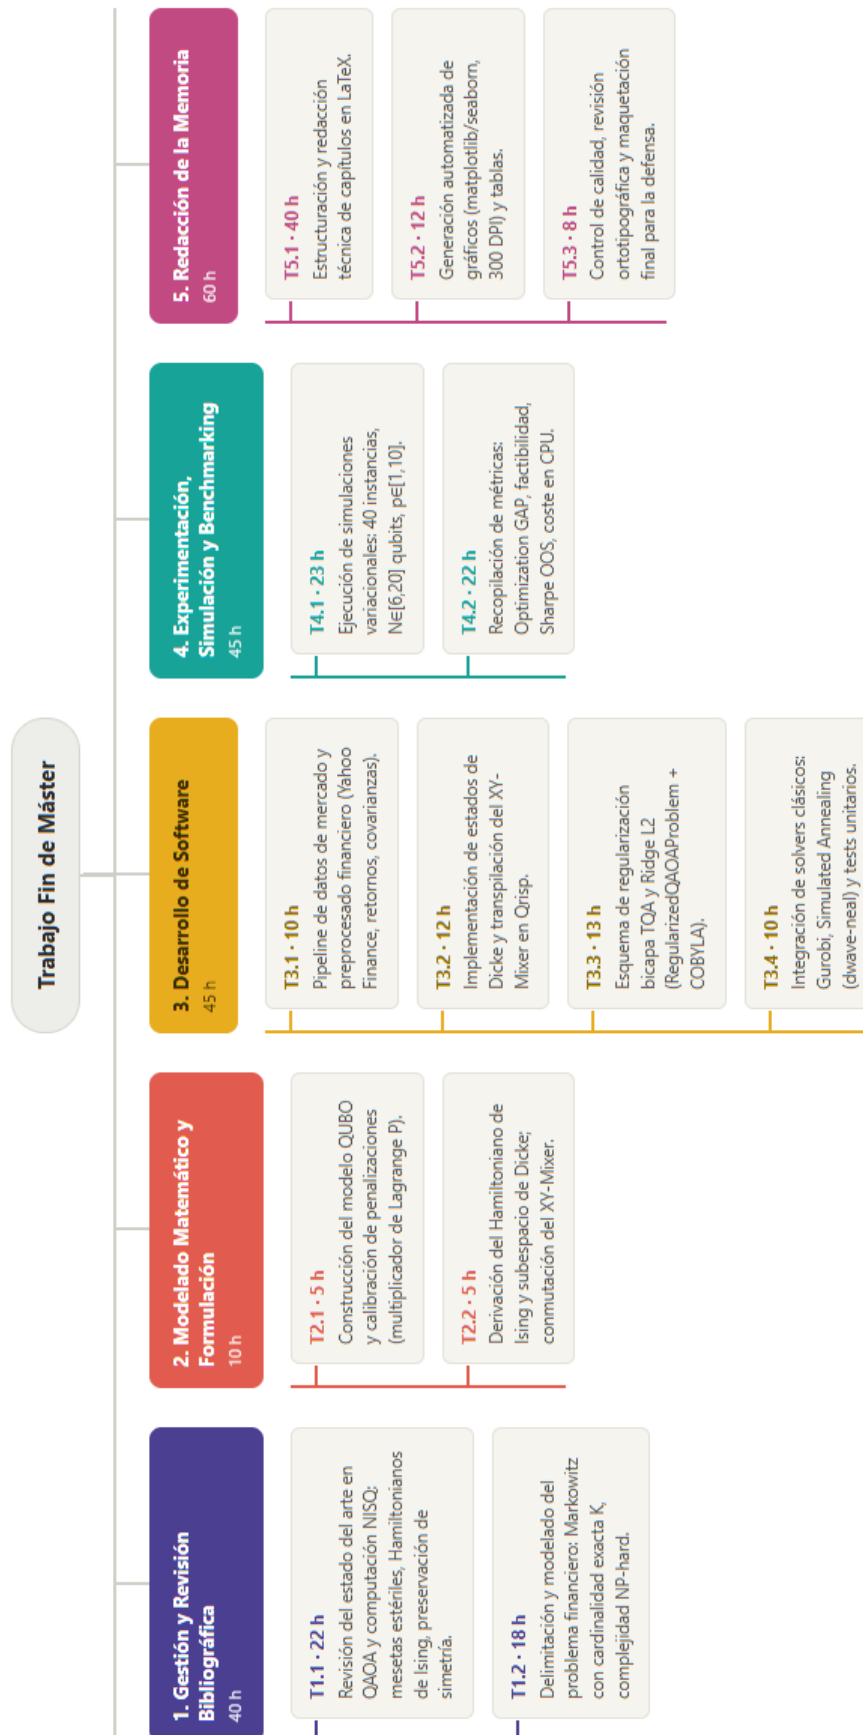


Figura 3.1.: Estructura de Descomposición del Trabajo del proyecto.

Cuadro 3.1.: Desglose detallado de dedicación horaria por paquete de trabajo y tarea (Total: 200 h).

Paquete (WP)	Tarea Específica / Actividad	Dedicación (h)
WP1: Revisión	T1.1. Estado del arte en QAOA, Barren Plateaus y NISQ	22
	T1.2. Delimitación y modelado de restricciones financieras	18
	Subtotal WP1	40
WP2: Modelado	T2.1. Construcción del modelo QUBO y calibración de penalización P	5
	T2.2. Derivación analítica del Hamiltoniano de Ising y simetría XY	5
	Subtotal WP2	10
WP3: Software	T3.1. Pipeline de descarga y preprocesado de datos de mercado	10
	T3.2. Implementación de estados de Dicke y transpilador XY-Mixer en Qrisp	12
	T3.3. Desarrollo del módulo de regularización bicapa TQA + Ridge L_2	13
	T3.4. Integración de solvers clásicos (Gurobi, SA) y verificación	10
	Subtotal WP3 (Desarrollo de Código)	45
WP4: Experim.	T4.1. Ejecución de campañas de simulación	23
	T4.2. Análisis de métricas (GAP, Viabilidad, Sharpe OOS, Tiempos)	22
	Subtotal WP4	45
WP5: Memoria	T5.1. Redacción técnica y estructuración de la memoria	40
	T5.2. Generación de gráficos vectoriales y cuadros	12
	T5.3. Revisión ortotipográfica, control de calidad y preparación de defensa	8
	Subtotal WP5 (Documentación y Diseminación)	60
TOTAL DEDICACIÓN EFECTIVA DEL PROYECTO		200

3.2. PLANIFICACIÓN TEMPORAL

3.2.1. Cronograma

El proyecto se planificó inicialmente para cinco meses, de febrero a junio, pensando en la convocatoria ordinaria. Sin embargo, el cronograma se alargó hasta finales de agosto para poder aplicar las correcciones y terminar la versión definitiva de la memoria.

En total se dedicaron 200 horas de trabajo individual. Para que el reparto del esfuerzo quede reflejado con claridad, se indica que en julio no hubo actividad (0 horas), la fase final de experimentación intensiva, el refinamiento del código y la redacción se concentraron en mayo, junio y agosto.

El cronograma temporal detallado y la distribución de los paquetes de trabajo se representan en el diagrama de Gantt de la Figura 3.2.




Figura 3.2.: Diagrama de Gantt.

3.3. PRESUPUESTO Y PLAN DE FINANCIACIÓN

Para evaluar la viabilidad económica y el coste real de transferencia tecnológica de la investigación, se presenta el desglose presupuestario del proyecto. La estimación económica se articula distinguiendo entre los costes directos de capital humano y los costes materiales derivados de la infraestructura computacional y el soporte operativo.

3.3.1. Costes de Personal

El cómputo de recursos humanos se deriva directamente de las 200 horas de dedicación individual efectiva del autor, distribuidas a lo largo de los cinco paquetes de trabajo del proyecto. Se establece una tarifa horaria de mercado estándar para un perfil de ingeniería de software cuántico y análisis cuantitativo de 35 €/h, lo que consolida un coste directo de personal de:

$$\text{Coste Personal} = 200 \text{ h} \times 35 \text{ €/h} = 7,000 \text{ €} \quad (3.1)$$

3.3.2. Otros Costes

A diferencia de desarrollos que dependen de software privativo de pago, este proyecto ha sido concebido bajo un paradigma estricto de *Open Science* y reproducibilidad, utilizando frameworks de código abierto (Qrisp, dwave-neal, dimod, SciPy) y licencias de uso académico sin coste comercial directo (Gurobi Optimizer API).

Por consiguiente, los costes no salariales se imputan de forma realista en función del desgaste de equipamiento físico, el suministro energético derivado del cómputo intensivo y el soporte auxiliar en la nube:

- **Amortización del Hardware de Desarrollo:** Computada sobre la estación de trabajo principal (procesador multinúcleo de alta frecuencia, 16 GB RAM y almacenamiento NVMe valorada en 1.500 €), asumiendo un periodo de vida útil de 36 meses y una imputación proporcional a los 5 meses de ejecución del TFM:

$$\text{Amortización HW} = \frac{1,500 \text{ €}}{36 \text{ meses}} \times 5 \text{ meses} \approx 208,33 \text{ €} \quad (3.2)$$

- **Consumo Eléctrico de Simulación:** Estimación del gasto energético derivado de las simulaciones con-

tinuadas de álgebra lineal densa (vectores de estado de 2^N dimensiones hasta $N = 20$) y benchmarking en CPU/GPU, asumiendo un consumo medio de 250 W durante las fases activas de cómputo: 45,00 €.

- **Entorno de Cómputo Auxiliar en la Nube (Google Colab Pro):** Suscripción temporal para la ejecución paralela y desatendida de campañas de calibración e hiperparametrización sin bloquear la estación de trabajo local: 60,00 €.
- **Herramientas de Versionado y Repositorio:** Uso de planes estándar de almacenamiento estructurado y pipelines de integración continua en GitHub: 0,00 €

3.3.3. Presupuesto Total

El Cuadro 3.2 consolida el coste presupuestario total del proyecto.

Cuadro 3.2.: Presupuesto financiero consolidado del proyecto de investigación.

Categoría	Concepto / Descripción	Base de Cálculo	Coste (€)
Recursos Humanos	Dedicación individual en ingeniería cuántica y finanzas	200 h $\times$ 35 €/h	7.000,00
Equipamiento Local	Amortización estación de trabajo (Intel i7, 16 GB RAM)	5 meses (vida útil 36 m.)	208
Energía y Suministros	Consumo eléctrico simulación statevectors (2^{20})	Estimación 250 W carga	45,00
Infraestructura Cloud	Suscripción Google Colab Pro para ejecuciones en paralelo	5 meses $\times$ 12 €/mes	60,00
Software y Licencias	Frameworks Open Source (QrISP, dwave) y Gurobi Académico	Licencias Open / Free	0,00
Coste total			7.313

4. MARCO TEÓRICO

4.1. INTRODUCCIÓN

En el Capítulo 2 se fijaron los objetivos del trabajo y las limitaciones de la literatura que se pretende abordar. Este capítulo desarrolla el fundamento matemático y algorítmico de la propuesta, organizado en tres bloques: primero, la traducción del problema de selección de carteras de Markowitz a un Hamiltoniano de Ising sobre cúbits; segundo, el análisis de la arquitectura estándar de QAOA, sus limitaciones, y la arquitectura con preservación de simetría propuesta en este trabajo; y tercero, los mecanismos de estabilización de la optimización clásica que la acompañan.

A diferencia del Capítulo 5, que detalla la implementación sobre datos reales —origen de los datos, herramientas empleadas y justificación de cada hiperparámetro—, aquí se presenta solo el fundamento matemático y teórico, independiente de cualquier instancia concreta del problema.

4.2. FORMULACIÓN MATEMÁTICA

4.2.1. El Modelo Continuo de Media-Varianza

Este trabajo parte del modelo de media-varianza de Markowitz [1], que compara el retorno esperado de una cartera con su riesgo. Dado un universo de N activos y un vector de pesos $w \in \mathbb{R}^N$, el retorno esperado de la cartera es:

$$\mu_p = \sum_{i=1}^N w_i \mu_i \quad (4.1)$$

donde μ_i es el retorno esperado del activo i . El riesgo se mide con la varianza:

$$\sigma_p^2 = \sum_{i=1}^N \sum_{j=1}^N w_i w_j \sigma_{ij} \quad (4.2)$$

donde σ_{ij} es el elemento (i, j) de la matriz de covarianza $\Sigma \in \mathbb{R}^{N \times N}$. El problema clásico consiste en maximizar μ_p y minimizar σ_p^2 a la vez, lo que da lugar a la conocida frontera eficiente de carteras óptimas.

4.2.2. Formulación QUBO

Para adaptar el modelo continuo a una arquitectura cuántica de cúbits, se introducen variables binarias $x_i \in \{0, 1\}$: $x_i = 1$ indica que el activo i entra en la cartera, y $x_i = 0$ que no. Con una estrategia de equiponderación y cardinalidad fija K , el peso de cada activo seleccionado es:

$$w_i = \frac{x_i}{K} \quad (4.3)$$

Se elige equiponderar en lugar de permitir pesos continuos porque así el problema queda estrictamente en el dominio combinatorio: el algoritmo solo debe decidir *qué* K activos incluir, no en qué proporción, lo cual encaja con el objetivo de evaluar los algoritmos cuánticos variacionales en problemas de selección combinatoria pura.

La restricción de cardinalidad exacta $\sum_{i=1}^N x_i = K$ es una restricción dura. Sin embargo, la formulación QUBO (Optimización Binaria Cuadrática No Restringida) no admite restricciones explícitas, así que esta debe incorporarse a la función objetivo como un término de penalización cuadrática:

$$P \left(\sum_{i=1}^N x_i - K \right)^2 \quad (4.4)$$

donde P es el multiplicador de penalización. Este término vale cero solo cuando se cumple exactamente la cardinalidad, y crece cuadráticamente con cualquier desviación.

Combinando las Ecuaciones (4.3) y (4.4) con el objetivo de media-varianza se obtiene la función de coste QUBO completa:

$$Q(x) = \lambda w^T \Sigma w - (1 - \lambda) \mu^T w + P \left(\sum_{i=1}^N x_i - K \right)^2 \quad (4.5)$$

donde $\lambda \in [0, 1]$ es el parámetro de aversión al riesgo, que pondera la varianza frente al retorno. Para que la penalización funcione, P debe dominar en magnitud al resto del objetivo: cualquier configuración factible (con exactamente K activos) debe tener siempre menor energía que cualquier configuración infactible, sin importar su calidad financiera. El criterio para fijar P en las instancias experimentales se detalla en el Capítulo 5.

Al expandir algebraicamente la Ecuación (4.5) se obtiene una matriz simétrica $Q \in \mathbb{R}^{N \times N}$: la diagonal recoge la contribución de cada activo, y el resto las interacciones entre pares de activos. Esta matriz Q es la representación QUBO completa del problema.

4.2.3. Mapeo al Hamiltoniano de Ising

Para llevar el problema QUBO al dominio cuántico, se expresa en términos de operadores de espín de Pauli. Esto se consigue con la transformación afín que relaciona cada variable binaria x_i con el operador Z_i de Pauli, de autovalores $\{-1, +1\}$:

$$x_i = \frac{I - Z_i}{2} \quad (4.6)$$

Sustituyendo esta ecuación en la función de coste QUBO (Ecuación (4.5)) y reagrupando términos, la función objetivo se reescribe como un Hamiltoniano de Ising:

$$H_P = \sum_{i=1}^N h_i Z_i + \sum_{i=1}^N \sum_{j>i}^N J_{ij} Z_i Z_j + O_{\text{ffset}} \quad (4.7)$$

Aquí, los coeficientes J_{ij} —los acoplamientos entre pares de cúbits— vienen de los elementos fuera de la diagonal de Σ , y los campos locales h_i combinan el vector de retornos μ con la parte lineal que aparece al expandir la penalización de cardinalidad (Ecuación (4.4)). El término O_{ffset} es una constante que no afecta a la posición del mínimo de energía.

Así, el problema de selección de carteras con cardinalidad exacta queda traducido a buscar el estado fundamental de un sistema de espines acoplados: la configuración $\{Z_i\}$ que minimiza H_P .

La Figura 4.1 resume este flujo, desde los datos financieros hasta la red de espines.




Figura 4.1.: Diagrama de flujo conceptual del mapeo matemático

4.3. ARQUITECTURA CUÁNTICA

4.3.1. QAOA Estándar y el Mezclador Transversal

Como se vio en el Capítulo 1, cada una de las p capas del circuito QAOA aplica el operador de coste $U_C(\gamma) = e^{-i\gamma H_P}$, que codifica el Hamiltoniano de Ising de la Ecuación (4.7), y un operador mezclador $U_M(\beta) = e^{-i\beta H_M}$, que redistribuye la probabilidad entre los estados de la base computacional.

En su versión estándar, el Hamiltoniano mezclador es la suma de rotaciones de bit (X) sobre cada cúbit:

$$H_M = \sum_{i=1}^N X_i \quad (4.8)$$

Este operador conecta directamente todos los estados de la base computacional, así que la evolución bajo $U_M(\beta)$ explora sin distinción el espacio de Hilbert completo (dimensión 2^N), incluyendo muchas configuraciones que violan $\sum_i x_i = K$. Con esta arquitectura, la única forma de evitar que el circuito converja a esas configuraciones infactibles es subir el multiplicador P de la Ecuación (4.4), lo que trae un problema adicional, como se ve a continuación.

4.3.2. Deformación del Paisaje y Barren Plateaus

Subir P para garantizar la factibilidad afecta directamente a la geometría del paisaje energético $\langle H_P \rangle(\gamma, \beta)$ que recorre el optimizador clásico. Al introducir un término que domina ampliamente al resto del objetivo financiero, el paisaje desarrolla gradientes de magnitud muy dispar entre regiones factibles e infactibles, lo cual dificulta la tarea del optimizador local.

Este fenómeno está relacionado con las llamadas mesetas estériles o *Barren Plateaus* [10]. McClean *et al.* demostraron que, en circuitos variacionales suficientemente expresivos, la varianza del gradiente de la función de coste decae exponencialmente con el número de cúbits:

$$\text{Var}[\partial_\theta \langle H \rangle] \sim \mathcal{O}\left(\frac{1}{2^N}\right) \quad (4.9)$$

Esta caída exponencial genera regiones extensas del paisaje donde el gradiente es, en la práctica, indistinguible de cero, e impide que optimizadores sin gradiente como COBYLA o SLSQP avancen hacia el óptimo. Penalizaciones grandes y mesetas estériles son, por tanto, dos problemas que se refuerzan mutuamente en el QAOA

estándar aplicado a restricciones duras (Figura 4.2).




Figura 4.2.: Representación conceptual del impacto de la varianza del gradiente en algoritmos variacionales.

Para resolver esta doble patología —exploración de estados infactibles y desvanecimiento del gradiente— se propone sustituir el mezclador transversal por un operador que confine la dinámica al subespacio factible de forma nativa, sin penalización. Las dos secciones siguientes desarrollan esta alternativa.

4.3.3. Estados de Dicke y Confinamiento Combinatorio

Un estado de Dicke $|D_K^N\rangle$ es la superposición uniforme de todas las configuraciones de N cúbits que tienen exactamente K cúbits en $|1\rangle$:

$$|D_K^N\rangle = \binom{N}{K}^{-1/2} \sum_{\substack{x \in \{0,1\}^N \\ |x|=K}} |x\rangle \quad (4.10)$$

donde $|x|$ es el peso de Hamming de la cadena x , es decir, su número de unos. Si el circuito se inicializa directamente en $|D_K^N\rangle$ —en vez de en la superposición uniforme $|+\rangle^{\otimes N}$ del QAOA estándar— y el mezclador conserva el peso de Hamming durante toda la evolución (se demuestra en la Sección 4.3.4), la dinámica queda confinada al subespacio de dimensión $\binom{N}{K}$, en lugar del espacio de Hilbert completo de dimensión 2^N .

El impacto de este confinamiento para distintos N y K se recoge en la Tabla 1.1 del Capítulo 1, y se ilustra en la Figura 4.3.




Figura 4.3.: Representación conceptual de la reducción de la dimensionalidad combinatoria.

4.3.4. El Operador de Mezcla XY

Para que la inicialización en el estado de Dicke funcione, hace falta sustituir el mezclador transversal (Ecuación (4.8)) por un operador cuya evolución conserve el peso de Hamming durante todo el circuito. Este trabajo usa el mezclador de intercambio de espín XY:

$$H_M^{XY} = \frac{1}{2} \sum_{\langle i,j \rangle} (X_i X_j + Y_i Y_j) \quad (4.11)$$

donde la suma recorre los pares de cúbits $\langle i, j \rangle$ acoplados según la topología del circuito. Este operador intercambia probabilidad entre dos cúbits solo cuando están en estados opuestos: actúa sobre el subespacio $\{|01\rangle, |10\rangle\}$ y deja invariantes $|00\rangle$ y $|11\rangle$.

Esta propiedad física lleva al resultado central que justifica la arquitectura propuesta: H_M^{XY} conmuta con el operador de peso de Hamming del sistema, $\sum_i Z_i$:

$$\left[H_M^{XY}, \sum_{i=1}^N Z_i \right] = 0 \quad (4.12)$$

Esta conmutación implica que H_M^{XY} y $\sum_i Z_i$ comparten una base de autoestados. Por eso, cualquier evolución generada por H_M^{XY} —y, por extensión, por la alternancia de $U_C(\gamma)$ y $U_M^{XY}(\beta)$, ya que $U_C(\gamma)$ es diagonal en la base computacional y también conserva el peso de Hamming— mantiene el peso de Hamming del estado inicial. Como el circuito se inicializa en $|D_K^N\rangle$, con peso de Hamming K , el estado permanece siempre dentro del subespacio de Dicke de dimensión $\binom{N}{K}$, sin necesidad de ningún término de penalización. Esta familia de *ansätze* con preservación de simetría, que confina el circuito al subespacio de peso de Hamming constante mediante mezcladores XY inicializados en estados de Dicke, se ha validado en simulación y en hardware real de trampa de iones para problemas de optimización combinatoria con restricciones [11, 12], y se ha aplicado a la selección de carteras en [14].

La Tabla 4.1 compara las propiedades de ambos mezcladores.

Cuadro 4.1.: Comparativa analítica entre el mezclador transversal (X) y el mezclador de intercambio (XY).

Propiedad	Mezclador X (Estándar)	Mezclador XY (Propuesto)
Expresión	$\sum_i X_i$	$\frac{1}{2} \sum_{\langle i,j \rangle} (X_i X_j + Y_i Y_j)$
Cantidad conservada	Ninguna	Peso de Hamming ($\sum_i Z_i$)
Espacio alcanzable	2^N (completo)	$\binom{N}{K}$ (subespacio de Dicke)
Requiere penalización de cardinalidad	Sí (Ecuación 4.4)	No

Para ver el efecto de este cambio en un caso mínimo, la Figura 4.4 muestra el hipercubo booleano de $N = 3$ cúbits con cardinalidad $K = 1$. El mezclador estándar conecta los ocho vértices del cubo, incluidos los seis infactibles; el mezclador XY, junto con la inicialización en el estado de Dicke, restringe la dinámica al plano de los tres vértices con peso de Hamming uno.



A. QAOA Estándar: Espacio Completo 2^N B. XY-QAOA: Subespacio de Dicke $\binom{N}{K}$ 

Figura 4.4.: Comparación geométrica sobre el hipercubo booleano de $N = 3$ cúbits con cardinalidad $K = 1$: el QAOA estándar (izquierda) recorre los ocho vértices, seis infactibles; el XY-QAOA (derecha) se limita al triángulo de los tres vértices factibles.

La Figura 4.5 muestra la topología completa del circuito propuesto: inicialización en el estado de Dicke seguida de capas sucesivas de $U_C(\gamma)$ y $U_M^{XY}(\beta)$.

4.4. ESTABILIZACIÓN DEL PAISAJE DE OPTIMIZACIÓN CLÁSICA

Aunque la arquitectura XY-QAOA de la Sección 4.3 resuelve por construcción el problema de factibilidad, el paisaje energético $\langle H_P \rangle(\gamma, \beta)$ puede seguir siendo rugoso y sensible a la inicialización de los parámetros, sobre todo en instancias con activos muy correlacionados. Para mitigarlo se usan dos mecanismos complementarios.

4.4.1. Trotterized Quantum Annealing (TQA)

En vez de inicializar (γ, β) al azar, se usa el esquema *Trotterized Quantum Annealing* (TQA) de Sack y Serbyn [15], que emula un recocido cuántico adiabático mediante una rampa temporal discretizada y, según sus autores, evita los mínimos falsos del paisaje en un amplio rango de pasos de Trotter. Para una profundidad de circuito




Figura 4.5.: Topología general del circuito cuántico XY-QAOA: inicialización determinista en el estado de Dicke, seguida por la aplicación iterativa de los operadores de coste $U_C(\gamma)$ y los operadores de mezcla con preservación de peso de Hamming $U_M^{XY}(\beta)$.

p , los ángulos iniciales de cada capa $m = 1, \dots, p$ se calculan como:

$$\gamma_m = \left(\frac{m}{p}\right) \Delta t, \quad \beta_m = \left(1 - \frac{m}{p}\right) \Delta t \quad (4.13)$$

donde Δt es la escala temporal del recocido simulado. En la práctica, se evalúa la energía del circuito para varios valores candidatos de Δt y se elige el que da menor energía antes de iniciar la optimización clásica. Este esquema no sustituye a la optimización posterior con COBYLA o SLSQP, sino que le da un punto de partida más cercano a la trayectoria adiabática teórica que una inicialización aleatoria.

4.4.2. Regularización Ridge L_2

Como segundo mecanismo, se añade una penalización Ridge (L_2) a la función de coste clásica que evalúa el optimizador. Con $\theta = (\gamma, \beta)$ el vector de parámetros y θ^{TQA} el ancla obtenida en la Sección 4.4.1, la función de coste regularizada es:

$$\mathcal{L}_{\text{Ridge}}(\theta) = \langle H_P \rangle_{\theta} + \alpha \sum_k (\theta_k - \theta_k^{\text{TQA}})^2 \quad (4.14)$$

donde $\alpha \geq 0$ es el coeficiente de regularización. Este término añade convexidad local alrededor del ancla TQA, penalizando trayectorias que se alejan mucho de esa región, y reduce el riesgo de que el optimizador quede atrapado en mínimos locales espurios causados por el ruido del muestreo cuántico.

Elegir α implica un compromiso sesgo-varianza: un valor muy alto ancla demasiado la solución al punto TQA inicial y le impide explorar soluciones mejores; un valor muy bajo no estabiliza la convergencia frente al ruido del paisaje. El valor usado en los experimentos, junto con su justificación empírica, se presenta en el Capítulo 5.4.4. La Figura 4.6 ilustra el efecto de esta regularización sobre el paisaje de coste.




Figura 4.6.: Efecto analítico de la regularización Ridge L_2 en el paisaje de energía de la función de coste. (Conceptual)

5. DESARROLLO DEL PROYECTO Y DISEÑO EXPERIMENTAL

5.1. INTRODUCCIÓN

El Capítulo 4 presentó el fundamento matemático del XY-QAOA regularizado: el mapeo Markowitz $\rightarrow$ QUBO $\rightarrow$ Ising, la arquitectura con preservación de simetría y los mecanismos de estabilización TQA y Ridge L_2 . Ese marco es independiente de cualquier instancia concreta: no dice qué datos se han usado, cuántos activos se han probado ni por qué se ha elegido un valor de regularización u otro. De eso trata este capítulo.

El objetivo de este capítulo es explicar cómo se ha pasado de la teoría del Capítulo 4 a los números y figuras del Capítulo 6. Cada decisión de diseño relevante –el rango de tamaños de universo, el número de reinicios por solver, el valor final de los hiperparámetros de regularización– se justifica aquí con evidencia empírica de estudios piloto, no por intuición. El Capítulo 6 se limita a interpretar esos resultados; no introduce ningún criterio de diseño nuevo.

Todas las figuras y tablas del Capítulo 6 se derivan de un único archivo, `output/results/results.csv`, generado por el script `scripts/run_benchmarks.py` con los parámetros finales que se fijan en este capítulo. La Sección 5.7 describe su estructura (768 filas, 15 columnas) y el procedimiento de generación. Cualquier número del Capítulo 6 puede rastrearse hasta una fila concreta de ese CSV, y este capítulo explica cómo.

El resto del capítulo se organiza en seis bloques: procedencia y preparación de los datos (Sección 5.2), arquitectura del software (Sección 5.3), calibración de hiperparámetros (Sección 5.4), gestión del presupuesto computacional (Sección 5.5), verificación y reproducibilidad (Sección 5.6) y descripción del experimento final (Sección 5.7).

5.2. RECOPIACIÓN Y PREPARACIÓN DE DATOS

5.2.1. Fuente de los datos

Los datos financieros son series históricas reales de precios de cierre ajustados, descargadas de Yahoo Finance mediante `scripts/prepare_data.py`. El universo de partida combina 30 activos del S&P 500 (por ejemplo, AAPL, MSFT, GOOGL, AMZN, JPM) y 10 del IBEX 35 (sufijo `.MC`: SAN.MC, BBVA.MC, TEF.MC, ITX.MC, REP.MC, IBE.MC, CABK.MC, SAB.MC, ACS.MC, FER.MC), para disponer de un conjunto amplio y diverso sobre el que cons-

truir subconjuntos de distintos tamaños.

Tras filtrar los tickers sin cotización simultánea en los regímenes usados para la división In-Sample / Out-of-Sample, el pipeline conserva un universo final de **40 activos comunes** (`tickers_all = 40`), sobre el que se muestrean todas las instancias experimentales del Capítulo 6.

5.2.2. Regímenes de mercado

Se construyeron tres regímenes de mercado, cada uno representando una condición macroeconómica distinta:

- **Estable** (01/01/2019 – 31/12/2019): un periodo con volatilidad moderada y tendencia sostenida, usado como referencia de condiciones “normales”.
- **Volátil (COVID-19)** (01/01/2020 – 31/12/2020): la ventana del choque de mercado provocado por la pandemia, elegida por ser el escenario más adverso para cualquier estrategia de asignación de activos.
- **Inflacionario** (01/01/2022 – 31/12/2023): un periodo de presión inflacionaria y subida de tipos de interés.

Cada régimen genera su propio par de archivos, `returns_annualized_<regimen>.csv` y `covariance_<regimen>.csv`, en `data/processed/`. El pipeline calcula los tres regímenes, pero el barrido del Capítulo 6 usa solo los dos primeros (Estable y Volátil-COVID19) para la división In-Sample / Out-of-Sample de la Sección 5.2.4; el régimen Inflacionario queda preparado como escenario adicional para una extensión futura del estudio (Capítulo 8).

5.2.3. Cálculo de retornos y de la matriz de covarianza

A partir de los precios de cierre ajustados se calculan retornos logarítmicos diarios para cada activo ($r_t = \ln(P_t/P_{t-1})$), anualizados multiplicando por 252 sesiones de negociación. La matriz de covarianza Σ se calcula igualmente sobre los retornos diarios y se anualiza con el mismo factor. Esta es la instanciación numérica de μ y Σ , que en la Sección 4.2.1 eran magnitudes puramente teóricas: aquí pasan a ser matrices y vectores calculados sobre datos de mercado reales.

5.2.4. División In-Sample / Out-of-Sample

El régimen **Estable** se usa como conjunto *In-Sample*: sobre él se ejecuta la optimización de cartera, tanto clásica como cuántica. El régimen **Volátil (COVID-19)** se reserva para evaluar el rendimiento *Out-of-Sample*, es decir, para calcular el Ratio de Sharpe que obtendría en la práctica una cartera seleccionada con datos de un periodo estable pero mantenida durante una crisis.

Esta elección es deliberada: evaluar el rendimiento *Out-of-Sample* precisamente en el régimen más adverso de los tres es la prueba más exigente que se le puede plantear al algoritmo. Cualquier estrategia puede parecer razonable si se evalúa en condiciones parecidas a las que se usaron para construirla; lo interesante es qué ocurre cuando el mercado se comporta de forma distinta a la esperada, y es esa la pregunta que responde esta división.

5.2.5. Selección de subconjuntos de N activos

Como el universo completo de 40 tickers es mayor que los tamaños de universo estudiados (el Capítulo 2 fija $N \leq 20$ como límite superior del alcance), hace falta un criterio para decidir, en cada experimento con un N concreto, qué N activos del universo total se seleccionan.

Este criterio se implementa mediante `get_nested_ticker_order`. Para cada semilla se genera una permutación determinista de los 40 tickers; los experimentos con tamaño N toman simplemente los primeros N elementos de esa permutación (`select_prefix_tickers`). Así, para una misma semilla, la instancia de $N = 8$ es un subconjunto de la de $N = 10$, que a su vez lo es de la de $N = 12$, y así sucesivamente.

Esta propiedad garantiza que, cuando en el Capítulo 6 se observe cómo varía una métrica al aumentar N , esa variación se deba solo al tamaño del problema y no a que hayan entrado o salido activos concretos con comportamientos distintos. Sin este diseño anidado, cualquier barrido en N estaría contaminado por una variable de confusión –qué activos componen cada instancia– difícil de separar de los resultados. La cardinalidad K se fija siempre como la mitad del universo, $K = \lfloor N/2 \rfloor$, para mantener el mismo ratio de selección (50 %) en todas las instancias.

5.3. ARQUITECTURA DEL SOFTWARE

5.3.1. Organización de módulos

El código se organiza separando claramente la formulación del problema, la simulación cuántica, los solucionadores de referencia y el cálculo de métricas:

```
src/
|- portfolio/portfolio_model.py    -> build_qubo(), qubo_to_ising():
|                                  Markowitz -> QUBO -> Ising (Ecs. 4.5-4.7)
|- quantum/classical_emulators.py -> QuantumStatevectorSimulator,
|                                  solve_qaoa_pure_numpy
|- solvers/classic_solvers.py      -> solve_gurobi, solve_sa
|- metrics/metrics.py              -> compute_gap, calculate_portfolio_metrics
scripts/
|- prepare_data.py                  -> descarga y regímenes de mercado
|- verify_oe1_isomorphism.py        -> verificación empírica de OE1
|- run_benchmarks.py               -> orquestador experimental completo
|- generate_section6_results_plots.py -> genera todas las figuras del Cap. 6
```

Esta organización refleja el flujo del Capítulo 4: los datos financieros se convierten en un problema QUBO, este se resuelve mediante simulación cuántica o solvers clásicos de referencia, y los resultados se comparan con un conjunto común de métricas.

Un detalle de implementación conecta directamente con la Ecuación (4.4): el multiplicador de penalización P no se fija a mano, sino que `build_qubo()` lo calcula automáticamente como $P = 10 \cdot \max_{i,j} |Q_{ij}^0|$, diez veces el mayor coeficiente (en valor absoluto) de la matriz QUBO sin penalizar Q^0 . Este criterio garantiza que la penalización domine en magnitud a los términos financieros del objetivo, cumpliendo la condición de la Sección 4.2.2 sin necesidad de ajustarla caso por caso.

5.3.2. El simulador de vector de estado

Todo el trabajo experimental se apoya en una simulación por vector de estado (*statevector*) implementada en NumPy puro, sin depender de un backend externo para la parte numérica. Esta decisión se explica en el

Capítulo 2 (Sección 2.2.1) como parte del alcance del proyecto; aquí se documentan las piezas que la hacen posible.

- `get_dicke_state()` / `get_superposition_state()`: construyen el vector de amplitudes de $|D_K^N\rangle$ (Ecuación (4.10)) o de $|+\rangle^{\otimes N}$, según el mezclador usado.
- `apply_cost_layer()`: aplica $U_C(\gamma)$ mediante una multiplicación de fase sobre una diagonal de energías precomputada, `self.E_diag`. Esta energía se calcula una sola vez para los 2^N estados posibles (en el constructor de la clase) y se reutiliza en todas las llamadas, de modo que cada evaluación cuesta $O(2^N)$ en lugar de recomputar la energía completa cada vez.
- `apply_rx_mixer_layer()` / `apply_xy_mixer_layer()` junto con `apply_xxyy_gate()`: implementan $U_M(\beta)$ para el mezclador estándar y para el XY (Ecuaciones (4.8) y (4.11)), mediante *reshape* y desplazamiento de ejes (`roll/swapaxes`) sobre el vector de estado, evitando construir matrices de $2^N \times 2^N$. Esto es lo que permite simular instancias de hasta $N = 20$ cúbits sin agotar la memoria disponible.

El coste asintótico es claro: cada evaluación completa del circuito cuesta $O(p \cdot 2^N)$, con p la profundidad del ansatz. Este crecimiento exponencial domina el presupuesto experimental de la Sección 5.4 y obliga a la gestión de tiempo de la Sección 5.5. La Sección 5.4.5 cuantifica este coste con datos medidos reales.

5.3.3. El bucle variacional

El bucle de optimización clásica se implementa en una única función, parametrizada por cuatro argumentos: el tipo de mezclador (`mixer = rx` o `xy`), el tipo de inicialización (`init_type = random` o `tqa`), la fuerza de la regularización Ridge (`alpha`) y la magnitud del ruido de inicialización (`jitter`).

Esta unificación es deliberada: en el experimento final se evalúan cinco solucionadores –Gurobi, Simulated Annealing, **Standard QAOA** (`mixer=rx`, `init_type=random`), **XY-QAOA** (`mixer=xy`, `init_type=random`), sin regularizar, ejecución única sin restarts, usado como control para aislar el efecto del mezclador XY) y **XY-QAOA Regularized** (`mixer=xy`, `init_type=tqa`, con *jitter*)– y los tres últimos son la misma función `solve_qaoa_pure_numpy` ejecutada con distintos parámetros. Así, cualquier diferencia observada en el Capítulo 6 entre estas variantes se debe a las diferencias algorítmicas que se quieren medir –mezclador, inicialización, regularización– y no a diferencias accidentales de implementación. Incluir XY-QAOA sin TQA permite además separar el efecto total en dos partes: cuánto aporta solo confinar la dinámica al subespacio de Dicke (Standard QAOA $\rightarrow$ XY-QAOA) y cuánto aporta, además, anclar la inicialización con TQA (XY-QAOA $\rightarrow$ XY-QAOA Regularized).

Para el ancla TQA (Ecuación (4.13)), el código evalúa 10 valores candidatos de Δt equiespaciados en $[0, 1, 1, 0]$ y elige, antes de iniciar el bucle de COBYLA, el que produce menor energía esperada del circuito.

El papel de `jitter` merece explicarse. El ancla TQA se calcula de forma determinista a partir de la matriz Q ; sin ningún elemento aleatorio, repetir el solver sobre la misma instancia daría siempre el mismo resultado, y el concepto de “mejor resultado de varios reinicios” –natural en el QAOA estándar por su inicialización aleatoria– no tendría sentido para la variante con *warm-start*. El parámetro `jitter` resuelve esto añadiendo una perturbación gaussiana, sembrada con la semilla del experimento (`instance['seed']`), al punto de partida de la optimización. Esta perturbación se aplica solo al punto de arranque, no al ancla θ^{TQA} de la Ecuación (4.14), que permanece fija en todo momento. Así, distintos reinicios de la variante regularizada exploran puntos de partida distintos sin que el término de estabilización pierda su referencia.

5.3.4. Solvers de referencia

Como puntos de comparación clásicos se usan dos solucionadores:

- `solve_gurobi`: resuelve el problema con el algoritmo exacto de ramificación y acotación (*Branch & Bound*) de Gurobi Optimizer, bajo licencia académica. Al ser un método exacto, proporciona la solución óptima verdadera con la que se mide el *Optimization GAP* de todos los demás solvers.
- `solve_sa`: implementa *Simulated Annealing* con la librería `dwave-neal`, configurada con `num_reads=500` y `num_sweeps=500` –inferior a los 1000/1000 que la función admite por defecto–, suficiente para que el algoritmo converja razonablemente sin disparar el tiempo de cómputo, ya que su papel es representar una heurística clásica rápida, no un competidor exhaustivo.

5.4. DISEÑO EXPERIMENTAL Y CALIBRACIÓN DE HIPERPARÁMETROS

En esta sección se documenta, con la mayor transparencia posible, por qué el experimento final tiene exactamente la forma que tiene. La lógica es siempre la misma: se plantea la pregunta de diseño, se describe el estudio piloto realizado para responderla, y se indica el valor que se fija para el experimento definitivo del Capítulo 6.

5.4.1. Métricas experimentales

Antes de la calibración, conviene definir las métricas que aparecen tanto en los estudios piloto de esta sección como en `results.csv` (Sección 5.7):

- **Optimization GAP (%)**: mide cuánto se aleja la energía obtenida por un solver de la energía óptima verdadera, calculada por Gurobi:

$$\text{GAP} = \frac{\text{obj}_{\text{solver}} - \text{obj}_{\text{Gurobi}}}{|\text{obj}_{\text{Gurobi}}|} \quad (5.1)$$

Esta métrica corresponde al criterio de éxito de OE4 (Sección 2.1.2). Si un solver iguala o mejora el óptimo de Gurobi, el GAP se satura a 0.

- **Feasibility Ratio (%)**: probabilidad, medida sobre el vector de estado final del circuito, de que una medición devuelva un estado que cumple la restricción de cardinalidad. Se calcula simulando el circuito con los ángulos óptimos y *el mismo mezclador que utilizó el solver evaluado*, y no siempre con RX, como ocurría en una versión temprana del código. Esta corrección importa porque, si no, la factibilidad del XY-QAOA se estaría midiendo con una dinámica distinta a la que realmente generó la solución.
- **Sharpe Ratio In-Sample / Out-of-Sample**: el Ratio de Sharpe de la cartera seleccionada, calculado sobre el régimen Estable (In-Sample) y sobre el régimen Volátil-COVID19 (Out-of-Sample), según la división de la Sección 5.2.4.
- **Execution Time (s)**: el tiempo de una única llamada al solver. Esta métrica no se acumula sobre el conjunto de reinicios: cada fila del CSV registra el tiempo de un único restart, no el tiempo total de la campaña.

5.4.2. Estructura del experimento: dos fases

El experimento final se organiza en dos fases, cada una pensada para aislar el efecto de una variable:

- **Fase de escalado en N (N-scaling)**: se fija la profundidad del circuito en $p = 3$ y se recorre $N \in \{6, 8, 10, 12, 14, 16, 18, 20\}$ (8 valores, en pasos de 2). Responde a cómo se comporta cada solver a medida que crece la dimensión del problema, evaluando los cinco solucionadores de la Sección 5.3.3.
- **Fase de escalado en p (p-scaling)**: se fija el universo en $N = 14$ ($K = 7$) y se recorre $p \in \{1, 2, \dots, 8\}$. Responde a cuánta profundidad de circuito hace falta para obtener buenos resultados, evaluando solo Gurobi, Standard QAOA y XY-QAOA Regularized, los tres solvers cuyo comportamiento depende de p .

El valor $N = 14$ no se elige al azar: es aproximadamente el punto medio del rango de N estudiado en la primera fase, lo que permite comparar el punto ($N = 14, p = 3$) –presente en ambas fases– como control de consistencia interna. Si los resultados de ambas fases coinciden razonablemente en ese punto común, esto refuerza la confianza en que no hay efectos espurios derivados de cómo se ha organizado el barrido.

5.4.3. Presupuesto de iteraciones de COBYLA

El número máximo de iteraciones que se concede al optimizador clásico COBYLA en cada llamada se calcula mediante la fórmula:

$$\text{maxiter} = \text{máx}(220, 120 + 45 \cdot p) \quad (5.2)$$

El presupuesto crece con p porque el ansatz tiene $2p$ parámetros libres (un ángulo γ y uno β por cada capa), y cuantos más parámetros hay que ajustar, más evaluaciones hacen falta para converger a una región estable del paisaje de coste. Esta fórmula se aplica igual a todos los solvers variacionales y a todos los valores de N y p : si cada solver tuviera un presupuesto distinto, la comparación entre ellos estaría sesgada de antemano, favoreciendo al que más iteraciones recibiera.

5.4.4. Calibración empírica de restarts, α y jitter: estudios piloto

Antes de comprometer el presupuesto computacional completo al barrido final de la Sección 5.4.2, se realizó un estudio piloto sobre instancias pequeñas para calibrar tres hiperparámetros: el número de reinicios por solver, la fuerza de la regularización Ridge (α) y la magnitud del ruido de inicialización (*jitter*). Este proceso responde al objetivo OE3 (Sección 2.1.2); documentarlo con honestidad, incluidos los resultados que no confirmaron la hipótesis inicial, forma parte del rigor metodológico del trabajo.

5.4.4.1. Número de reinicios (restarts)

El experimento final fija `standard_restarts = 1` y `regularized_restarts = 1` para todos los valores de N y p . No es una elección arbitraria: refleja el régimen de recursos que motiva este trabajo. En un dispositivo NISQ real, cada restart no es una repetición gratuita, sino una ejecución completa del circuito cuántico, con su coste en cola de ejecución y su exposición al ruido y la decoherencia del hardware. Permitir muchos restarts cambiaría la pregunta que este trabajo quiere responder: no “¿qué solver resuelve mejor el problema con cómputo clásico ilimitado?”, sino “¿qué solver da mejor resultado con el mínimo de disparos posible en un escenario de

hardware cuántico limitado?”.

Hay también una razón estructural, no solo práctica, para fijar el presupuesto de restarts en 1. El coste de una sola evaluación del solver crece de forma exponencial con N ($O(2^N)$): un número de restarts razonable en instancias pequeñas se vuelve inviable a medida que N crece, precisamente en el rango de tamaños grandes donde tendría sentido recurrir a computación cuántica. Un solver cuya ventaja dependa de tener muchos restarts la perdería justo donde más falta hace; uno cuya ventaja venga, en cambio, de una estructura algorítmica informada –como el confinamiento al subespacio de Dicke del mezclador XY y la inicialización TQA– no depende de ese presupuesto, y por eso es la propiedad relevante para el régimen de N grande que motiva este proyecto. Esta hipótesis queda como línea futura de trabajo en el Capítulo 8: confirmarla de forma concluyente para N mayor de 20 exigiría un simulador distinto al de vector de estado, por el mismo coste $O(2^N)$.

Para separar la contribución de la inicialización TQA del efecto del mezclador XY, se comparó, sobre el barriado principal de `results.csv` ($N = 6$ a $N = 20$, 12 semillas, mismo mezclador XY en ambos casos), XY-QAOA con inicialización aleatoria frente a XY-QAOA Regularized con inicialización TQA, mediante un test de Wilcoxon pareado por semilla para cada valor de N (script `scripts/run_stats_tests.py`, resultados en `output/results/stats_tests_results.csv`). El resultado no muestra diferencia estadísticamente significativa en el GAP medio en ninguno de los ocho valores de N evaluados (p entre 0,07 y 0,90), y la reducción de la desviación estándar del GAP atribuible a TQA es inconsistente según N (entre $-11,2\%$ y $+34,1\%$, media $6,4\%$). Con esta evidencia, la mayor parte de la ventaja de XY-QAOA Regularized frente a Standard QAOA se atribuye al confinamiento del subespacio de Dicke por el mezclador XY, y no a la inicialización TQA por sí sola.

5.4.4.2. Regularización Ridge (α)

A diferencia del estudio de restarts, la calibración de α se registró como experimento reproducible independiente, ejecutable mediante `python scripts/run_benchmarks.py -alpha-ablation` y almacenado en `output/results/alpha_ablation.csv`. El estudio compara, sobre instancias con $N \in \{6, 8, 10, 12, 14\}$ ($K = N/2$), $p = 3$ y cinco semillas (42–46), la variante regularizada con $\alpha = 0$ frente a la misma con $\alpha = 0,1$, midiendo el Optimization GAP resultante en cada caso.

La Tabla 5.1 recoge el GAP medio (y su desviación estándar entre semillas) para cada N . El resultado es consistente en los cinco tamaños evaluados: activar el término Ridge *empeora* el GAP medio en todos los casos, entre 1,4 y 3,0 veces peor según el tamaño. Agregando las 25 observaciones de cada grupo, el GAP medio pasa de $19,16\%$ ($\alpha = 0$) a $36,38\%$ ($\alpha = 0,1$).

Cuadro 5.1.: Ablación de la regularización Ridge: Optimization GAP medio (%) $\pm$ desviación estándar entre 5 semillas, con y sin el término Ridge activo ($p = 3$).

N ($K = N/2$)	Sin Ridge ($\alpha = 0$)	Con Ridge ($\alpha = 0,1$)
6	15,91 $\pm$ 11,27	21,62 $\pm$ 20,79
8	13,36 $\pm$ 8,02	40,23 $\pm$ 14,94
10	17,57 $\pm$ 11,46	43,31 $\pm$ 27,85
12	23,58 $\pm$ 13,22	40,33 $\pm$ 12,08
14	25,39 $\pm$ 15,83	36,41 $\pm$ 7,27
Global (todas las N)	19,16 $\pm$ 12,11	36,38 $\pm$ 18,26

La Figura 5.1 muestra esta comparación por tamaño de universo, y la Figura 5.2 muestra que activar el término Ridge tampoco aporta ninguna ventaja en tiempo de cómputo: el coste por evaluación es equivalente en ambos casos, ya que el término de penalización añade un cálculo vectorial trivial frente al coste dominante de la simulación del circuito.




Figura 5.1.: Optimization GAP medio con y sin regularización Ridge, por tamaño de universo N . Los intervalos representan la desviación estándar entre semillas. Datos: `output/results/alpha_ablation.csv`.

Este resultado se presenta aquí como parte de la calibración –la discusión de por qué ocurre se deja para el Capítulo 6–, pero conviene ser claro sobre lo que significa: el objetivo OE3 pedía *evaluar* el efecto estabilizador de la regularización Ridge, no asumir que ese efecto existiría de antemano. Documentar que, tras una calibración




Figura 5.2.: Tiempo de ejecución con y sin regularización Ridge, por tamaño de universo N .

empírica reproducible, el mecanismo Ridge no mejoró el resultado –y de hecho lo empeoró– en las instancias estudiadas es una conclusión legítima del proceso de investigación. En consecuencia, el experimento final fija `regularized_alpha = 0,0`, lo que equivale a desactivar por completo el término Ridge de la Ecuación (4.14) en todas las figuras del Capítulo 6. Por este motivo, el solver que en el código y en `results.csv` se etiqueta internamente como "XY-QAOA Regularized" se presenta en las figuras del Capítulo 6 bajo la etiqueta **XY-QAOA (TQA)**: el nombre refleja lo que el solver hace realmente en la configuración final –inicialización TQA con *jitter*– y no un mecanismo de regularización Ridge que, tras la calibración, quedó desactivado.

5.4.4.3. Ruido de inicialización (*jitter*)

Por último, se exploraron distintos valores de la desviación estándar del ruido gaussiano aplicado al punto de partida, entre 0,0 y 1,0 radianes. Se fijó `regularized_jitter = 0,6` como valor por defecto de la interfaz de línea de comandos, por ofrecer suficiente diversidad entre reinicios sin degradar de forma apreciable la calidad de cada solución individual.

5.4.5. Escalado en N : análisis de coste computacional

Como se señaló en la Sección 2.2.2, el estudio se limita a universos de hasta $N = 20$ activos. Esta decisión no es arbitraria, sino el resultado de medir el coste real de la simulación. La Tabla 5.2 recoge el tiempo medio de una llamada completa al solver (inicialización TQA más bucle completo de COBYLA hasta `maxiter`), medido directamente sobre las filas de `results.csv` para Standard QAOA y XY-QAOA Regularized en la fase de N-scaling ($p = 3$ fijo), para cada valor de N estudiado.

Cuadro 5.2.: Tiempo de ejecución medio de una llamada completa al solver variacional, en función de N (con $p = 3$ fijo). Promedio sobre Standard QAOA y XY-QAOA Regularized, 12 semillas por punto.

N	6	8	10	12	14	16	18	20
Tiempo (s)	0,30	0,33	0,40	0,58	1,12	3,53	16,10	208,49

El crecimiento observado es claramente exponencial, coherente con el comportamiento $O(2^N)$ anticipado en la Sección 5.3.2: entre $N = 18$ y $N = 20$, el tiempo se multiplica por más de 12, mientras que entre $N = 6$ y $N = 12$ apenas se duplica. Este dato justifica mantener $N = 20$ como techo del estudio: superar ese límite habría multiplicado el tiempo de cada llamada hasta un punto en el que el barrido completo de semillas dejaría de ser viable dentro del tiempo de cómputo disponible. El número de semillas del experimento final (`seed_count`) se calibra precisamente para que el barrido completo, con este coste por evaluación, quepa en el presupuesto de tiempo sin reducir el número de restarts ni el rango de N de forma desigual entre configuraciones. El mecanismo que gestiona este presupuesto se describe en la Sección 5.5.

5.5. GESTIÓN DEL PRESUPUESTO COMPUTACIONAL

Dado el coste exponencial en N documentado en la Sección 5.4.5, un único punto de $N = 20$ puede dominar por completo el tiempo total de un barrido experimental si no se gestiona de forma explícita. Por eso, además de la calibración a priori de la sección anterior, `run_benchmarks.py` incorpora un mecanismo de seguridad adicional: un presupuesto de tiempo total (`max_hours`, 4 horas por defecto) que se reparte entre las dos fases del experimento, asignando un 65 % a la fase de N-scaling y un 30 % a la de p-scaling (el 5 % restante queda como margen de seguridad para el resto de tareas del script).

Este mecanismo funciona mediante *deadlines* de tiempo asignados a cada fase. Si el presupuesto de una fase se agota antes de completar todas las combinaciones previstas de N (o p), semilla y solver, el script no falla ni descarta el trabajo ya realizado: captura la excepción interna `BudgetExceeded`, guarda de forma segura los

resultados acumulados hasta ese momento y finaliza la fase de forma controlada. Esto permite ejecutar el barrido completo en máquinas con distinta capacidad de cómputo sin arriesgarse a perder el trabajo ya realizado si el tiempo disponible resulta más ajustado de lo previsto.

En la ejecución final que generó los datos del Capítulo 6, este mecanismo de emergencia no llegó a activarse: el tiempo total real de ejecución fue de 8038,3 segundos (aproximadamente 2 h 14 min), muy por debajo del presupuesto de 4 horas asignado (7612,9 s para la fase de N-scaling y 425,4 s para la de p-scaling). Que no se activara no le resta valor: forma parte del diseño experimental como red de seguridad, y garantiza que, si se repitiera esta campaña en una máquina más lenta, el experimento seguiría produciendo un conjunto de datos íntegro y sin combinaciones N/seed/solver a medio completar.

5.6. VERIFICACIÓN Y REPRODUCIBILIDAD

La correcta implementación del mapeo teórico del Capítulo 4 se verifica mediante dos mecanismos complementarios:

- **Verificación del mapeo Markowitz → QUBO → Ising:** `elscripts/scripts/verify_oe1_isomorphism.py` verifica empíricamente el cumplimiento de OE1 (Sección 2.1.2). Para instancias con $N \in \{6, 8, 10, 12, 14\}$ y tres semillas (42, 43, 44; 15 combinaciones en total), se comparan por fuerza bruta, sobre la totalidad de las 2^N configuraciones binarias posibles, la energía del Hamiltoniano de Ising construido y el valor de la función objetivo QUBO original. El resultado, recogido en `output/results/oe1_verification.csv`, confirma que ambas representaciones coinciden en las 15 combinaciones evaluadas (`passed = True` en el 100 % de los casos), con una discrepancia numérica máxima de $5,33 \times 10^{-14}$ –varios órdenes de magnitud por debajo de cualquier tolerancia razonable de punto flotante de doble precisión– y coincidencia exacta del estado fundamental identificado por ambas representaciones en todos los casos.
- **Política de semillas:** todos los experimentos presentados en este trabajo son reproducibles a partir de una semilla inicial (`seed_start=42`) y de un conjunto de semillas documentado explícitamente en la configuración del experimento (Sección 5.7), en línea con la práctica de reproducibilidad declarada en el Alcance del proyecto (Sección 2.2.1).

Una limitación honesta del repositorio actual: aunque `requirements.txt` declara `pytest` como dependencia con vistas a una suite de tests unitarios que cubriera formalmente propiedades como la construcción correcta del QUBO o la conmutación del mezclador XY con el operador de peso de Hamming (Ecuación (4.12)), dicha

suite no se ha llegado a implementar como un directorio `tests/` independiente en la versión actual del código. La verificación formal se apoya, por tanto, en los dos mecanismos descritos arriba –el script de verificación de OE1 y la política de semillas–, y la implementación de una batería de tests unitarios queda como línea de mejora en el Capítulo 8 (Conclusiones y trabajo futuro).

5.7. GENERACIÓN DEL DATASET EXPERIMENTAL

Esta última sección cierra el capítulo describiendo la ejecución completa de `scripts/run_benchmarks.py`, con su configuración por defecto: $N_{\text{máx}} = 20$ (barrido $N \in \{6, 8, \dots, 20\}$), `seed_start= 42`, `seed_count= 12` (semillas 42 a 53), `standard_restarts= 1`, `regularized_restarts= 1`, `regularized_alpha= 0,0`, `regularized_jitter= 0,6`, $\lambda = 0,5$, `sa_reads=sa_sweeps= 500` y un presupuesto de tiempo de 4 horas. El tiempo total real de ejecución fue de 8038,3 segundos, como se detalla en la Sección 5.5.

El archivo `results.csv` resultante contiene **768 filas y 15 columnas**: una fila por cada evaluación individual de un solver –incluyendo cada reinicio por separado, identificado mediante `restart_id` e `is_best_restart`– junto con todas las columnas de métricas de la Sección 5.4.1 (`N`, `K`, `Solver`, `p`, `seed`, `restart_id`, `is_best_restart`, `experiment_phase`, `Feasibility Ratio (%)`, `Optimization GAP (%)`, `gap_best_of_restarts`, `Sharpe Ratio In-Sample`, `Sharpe Ratio Out-of-Sample`, `Execution Time (s)` y `objective`). De esas 768 filas, 480 corresponden a la fase de N-scaling (8 valores de $N \times 12$ semillas $\times$ 5 solvers) y 288 a la fase de p-scaling (8 valores de $p \times 12$ semillas $\times$ 3 solvers).

Todas las figuras, tablas y estadísticos presentados en el Capítulo 6 se derivan exclusivamente de este `results.csv`, mediante el script `scripts/generate_section6_results_plots.py`, sin ningún cálculo o dato adicional introducido en la fase de análisis. Este script agrupa las observaciones por solver y dimensión (filtrando, cuando corresponde, únicamente la mejor ejecución de cada conjunto de restarts a través de `is_best_restart`) y genera cada figura de forma determinista a partir de esos datos agregados. Esto deja constancia de que el Capítulo 6 no introduce ningún grado de libertad no documentado ya en este capítulo.

6. EVALUACIÓN Y ANÁLISIS DE RESULTADOS

6.1. INTRODUCCIÓN Y METODOLOGÍA DE ANÁLISIS

Este capítulo interpreta los datos generados según el procedimiento de la Sección 5.7: todas las figuras y tablas se derivan de `output/results/results.csv`, agregando las 768 observaciones por Solver y por dimensión (N o p , según la fase) mediante la media entre las 12 semillas de cada combinación, tomando siempre la ejecución `is_best_restart=True` cuando el solver tiene más de un reinicio. Este capítulo no introduce ningún criterio de diseño nuevo respecto al Capítulo 5; se limita a leer sus consecuencias numéricas.

A lo largo del capítulo se mantiene una convención de solver constante:

- **Gurobi**: solucionador exacto de referencia, $GAP = 0\%$ por construcción.
- **Simulated Annealing (SA)**: metaheurística clásica estocástica de referencia.
- **Standard QAOA**: mezclador transversal X , inicialización aleatoria, penalización cuadrática de cardinalidad.
- **XY-QAOA**: mezclador XY con inicialización de Dicke, sin regularización ni TQA (aísla el efecto exclusivo del confinamiento combinatorio).
- **XY-QAOA Regularizado**: mezclador XY + inicialización TQA + *jitter* (Sección 4.4.1; el término Ridge está desactivado, $\alpha = 0$, según la calibración de la Sección 5.4.4.2).

Todos los solvers variacionales operan con un único reinicio (`standard_restarts=1, regularized_restarts=1`), fijado en la Sección ?? como el escenario más representativo de una ejecución en hardware cuántico real. Esta condición es clave para interpretar las cifras de este capítulo y se recuerda donde resulta relevante.

6.2. GAP DE OPTIMIZACIÓN FRENTE AL TAMAÑO DEL PROBLEMA (N)

Simulated Annealing muestra una degradación casi monótona con N : parte de un GAP nulo hasta $N = 10$ y crece de forma sostenida hasta estabilizarse en una meseta de 4–4,5% a partir de $N = 16$, sin empeorar de forma apreciable entre $N = 18$ y $N = 20$. Es el solver heurístico clásico más estable de los evaluados: su




Figura 6.1.: Optimization GAP medio (%) frente al tamaño de universo N , para Simulated Annealing, Standard QAOA y XY-QAOA Regularizado ($p = 3$, 1 restart, 12 semillas por punto)

desviación estándar entre semillas nunca supera 2,7 puntos porcentuales.

Standard QAOA presenta un patrón muy distinto: no monótono, con oscilaciones amplias (mínimo de 17,87 % en $N = 8$, máximo de 62,38 % en $N = 18$, y una caída posterior hasta 31,29 % en $N = 20$) y una desviación estándar que en todos los puntos es del mismo orden que la propia media, llegando a superarla ($N = 6$: media 28,23, desviación 37,61). Es lo esperable bajo un único reinicio con inicialización aleatoria: con una sola muestra del punto de partida, el resultado de cada semilla depende de si esa inicialización cayó cerca o lejos de una región favorable del paisaje energético, y el promedio entre 12 semillas hereda esa varianza.

XY-QAOA Regularizado muestra la curva más suave de los tres solvers variacionales: crece de forma leve entre $N = 6$ (10,85 %) y $N = 12-14$ (en torno al 21–22 %), y a partir de ahí se mantiene en meseta (19–22 %) hasta $N = 20$, con una desviación estándar sustancialmente menor que la de Standard QAOA en todos los puntos (entre 6,7 y 14,2 puntos, frente a los 34–48 de Standard QAOA).

Conviene tener en cuenta el marco correcto para leer esta figura: como cada punto corresponde a una única ejecución del circuito por semilla, lo que se mide no es “el mejor resultado que QAOA puede alcanzar”, sino el resultado esperable con un presupuesto de ejecución mínimo, análogo a una única pasada en un dispositivo NISQ real donde cada reinicio adicional tiene un coste físico (Sección ??). Bajo esa lectura, comparar Standard QAOA con XY-QAOA Regularizado no es comparar la calidad máxima alcanzable, sino *qué tan bien se comporta*

cada arquitectura con el mínimo de información y repeticiones posible.

Con esa salvedad, el dato es claro: XY-QAOA Regularizado obtiene un GAP medio menor que Standard QAOA en los ocho valores de N evaluados, sin excepción. La magnitud de esa diferencia no sigue una tendencia monótona con N : oscila entre 3,9 puntos porcentuales ($N = 8$) y 42,2 puntos porcentuales ($N = 18$), este último coincidiendo con el peor comportamiento absoluto de Standard QAOA.

En conjunto, el orden de mérito en GAP es claro y estable en todo el rango: Simulated Annealing < XY-QAOA Regularizado < Standard QAOA. La diferencia entre Simulated Annealing y XY-QAOA Regularizado es, además, estadísticamente significativa en los ocho valores de N (test de Wilcoxon pareado por semilla, $p < 0,01$ en todos los casos; véase `output/results/stats_tests_results.csv`), por lo que no se debe al azar de muestreo entre semillas.

6.3. ROBUSTEZ FINANCIERA: RATIO DE SHARPE FUERA DE MUESTRA




Figura 6.2.: Ratio de Sharpe medio frente a N : Gurobi In-Sample, Gurobi Out-of-Sample y XY-QAOA Regularizado Out-of-Sample.

El primer dato relevante de esta figura no involucra a ningún solver cuántico: la comparación entre el Sharpe In-Sample y Out-of-Sample de Gurobi muestra una caída sistemática de entre el 65 % y el 73 % del ratio al pasar del régimen Estable al Volátil-COVID19, independientemente de N (por ejemplo, en $N = 14$, de 2,613 a 0,782). Esta degradación es el “suelo” inevitable que impone el cambio de régimen de mercado sobre cualquier cartera,

óptima o no, y no debe atribuirse a ninguna limitación algorítmica.

La comparación relevante para evaluar la robustez del método cuántico es, por tanto, XY-QAOA Regularizado (OOS) frente a Gurobi (OOS) –no frente a Gurobi In-Sample–, ya que ambas curvas están sujetas al mismo choque de régimen. Bajo ese criterio: en $N = 6$, el Sharpe OOS de XY-QAOA Regularizado (0,656) supera ligeramente al de Gurobi OOS (0,587); esto se reporta como dato observado, sin atribuirle una causa estructural –puede deberse simplemente a qué activos selecciona cada solver en una instancia pequeña con poco margen de variación combinatoria. En el resto del rango ($N = 8$ a $N = 20$), Gurobi OOS es sistemáticamente superior, con el Sharpe OOS de XY-QAOA Regularizado entre el 76,5 % ($N = 16$ y $N = 20$) y el 95,3 % ($N = 8$) del valor de Gurobi OOS, sin una tendencia clara de acercamiento o alejamiento progresivo con N .

Estadísticamente, ninguna de estas diferencias es significativa (test de Wilcoxon pareado por semilla, $p > 0,05$ en los ocho valores de N ; el valor más bajo es $N = 14$ con $p = 0,052$). Con la evidencia disponible, XY-QAOA Regularizado y Gurobi son, por tanto, financieramente comparables fuera de muestra en el rango estudiado.

6.4. COSTE TEMPORAL Y ESCALABILIDAD




Figura 6.3.: Tiempo de ejecución medio (s, escala logarítmica) frente a N , para Gurobi, Simulated Annealing, Standard QAOA y XY-QAOA Regularizado.

La escala logarítmica del eje de tiempos es necesaria: el rango cubierto abarca más de cuatro órdenes de magnitud, desde los 4–7 milisegundos de Gurobi (prácticamente insensible a N en este rango) hasta las decenas o

Cuadro 6.1.: Tiempo de ejecución medio (s) por solver y tamaño de universo N ($p = 3$).

N	Gurobi	Sim. Annealing	Standard QAOA	XY-QAOA Regularizado
6	0,0041	0,0130	0,292	0,302
8	0,0043	0,0182	0,327	0,327
10	0,0046	0,0235	0,393	0,398
12	0,0051	0,0291	0,549	0,618
14	0,0048	0,0356	1,115	1,133
16	0,0056	0,0421	3,135	3,927
18	0,0060	0,0484	15,491	16,708
20	0,0067	0,0565	257,344	159,633

cientos de segundos de la familia QAOA en $N = 20$.

Las curvas de Standard QAOA y XY-QAOA Regularizado son visualmente rectas en el tramo logarítmico-lineal a partir de $N \approx 12$, la firma típica de un crecimiento exponencial en N . Esto es justo lo que anticipa el análisis de coste asintótico $O(p \cdot 2^N)$ de la Sección 5.3.2, cuantificado empíricamente en la Sección 5.4.5 (Tabla 5.2): el tiempo por evaluación se multiplica por más de $12\times$ entre $N = 18$ y $N = 20$ para ambos solvers variacionales, frente a un crecimiento casi plano de Gurobi y SA en el mismo tramo.

Entre los dos solvers variacionales, el crecimiento no es idéntico en todo el rango: hasta $N = 16$, XY-QAOA Regularizado es ligeramente más lento que Standard QAOA en cada punto (por ejemplo, 3,927 s frente a 3,135 s en $N = 16$), coherente con el coste algo mayor de aplicar el operador de intercambio XY (Ecuación (4.11)) frente al mezclador transversal de un cúbit (Ecuación (4.8)). En $N = 20$, sin embargo, se invierte esta relación: XY-QAOA Regularizado completa su ejecución en 159,6 s frente a los 257,3 s de Standard QAOA. Este cruce es coherente con la inicialización TQA (Sección 4.4.1): al partir de un punto ya cercano a una región de baja energía, COBYLA puede alcanzar su criterio de convergencia en menos evaluaciones que el límite $\max_{iter}$ de la Ecuación (5.2), mientras que una inicialización aleatoria tiende a agotar el presupuesto completo con más frecuencia; ambos solvers comparten el mismo tope de iteraciones y el mismo coste por evaluación, así que la diferencia en $N = 20$ solo se explica por un número efectivo de evaluaciones distinto.

El punto en el que las curvas clásica y cuántica se separan de forma drástica está entre $N = 14$ y $N = 16$: hasta $N = 14$, toda la familia QAOA se mantiene por debajo del segundo y medio; a partir de $N = 16$, el tiempo se dispara por encima de los 3 segundos y sigue creciendo exponencialmente. Este umbral empírico sustenta la discusión del Capítulo 8 sobre los límites prácticos de la simulación clásica exacta, mencionados en el criterio de éxito de OE4.

6.5. FACTIBILIDAD ESTRUCTURAL DE LAS SOLUCIONES




Figura 6.4.: Tasa de factibilidad media (%) frente a N : Standard QAOA frente a XY-QAOA. Las bandas sombreadas representan ± 1 desviación estándar entre 12 semillas.

La curva de XY-QAOA es una línea plana en el 100 % para los ocho valores de N , con desviación estándar nula en todos los puntos. Esto no es un hallazgo empírico frágil sujeto al azar del muestreo, sino una **verificación de consistencia** entre la teoría del Capítulo 4 y la implementación: como el operador XY conmuta exactamente con el operador de peso de Hamming (Ecuación (4.12)) y el circuito se inicializa en el estado de Dicke, la dinámica queda confinada al subespacio factible por construcción matemática; cualquier desviación de esta curva respecto al 100 % habría señalado un error de implementación, no una limitación física del algoritmo.

La curva de Standard QAOA exige más atención. Su tendencia central es decreciente con N , desde un 93,92 % en $N = 6$ hasta un 51,70–51,76 % en $N = 18$ –20: en las instancias más grandes, poco más de la mitad de la masa de probabilidad del estado final cae, en promedio, sobre configuraciones que cumplen la restricción de cardinalidad. Pero esta media va acompañada de una dispersión creciente: la desviación estándar entre semillas pasa de 3,19 puntos en $N = 6$ a 27,76–28,10 puntos en $N = 18$ –20, lo que indica que, en las instancias grandes, una semilla concreta puede caer entre factibilidad casi total y factibilidad muy baja según dónde haya aterrizado la inicialización aleatoria. Esta variabilidad es coherente con el régimen de un único reinicio (Sección ??): con una sola muestra por semilla, la media de 12 observaciones dispersas es necesariamente menos informativa que la media de un conjunto con baja varianza, como la curva de XY-QAOA.

6.6. EFECTO DE LA PROFUNDIDAD DEL CIRCUITO (p)




Figura 6.5.: Efecto de la profundidad del circuito p sobre el Optimization GAP (izquierda) y el tiempo de ejecución (derecha), con $N = 14$ fijo. Standard QAOA frente a XY-QAOA Regularizado.

En `gap_vs_p`, el comportamiento observado se aleja de la expectativa teórica del QAOA, según la cual más capas p deberían, en general, acercar el resultado al óptimo al añadir grados de libertad variacional. Para Standard QAOA, el GAP no decrece de forma monótona con p : oscila entre un mínimo de 16,85 % ($p = 7$) y un máximo de 70,85 % ($p = 8$), sin tendencia identificable, con una desviación estándar que en todos los puntos iguala o supera a la propia media. Este comportamiento errático es de nuevo coherente con el régimen de un único reinicio: cada punto de la curva es, en la práctica, una muestra aleatoria del paisaje energético por semilla, y con un espacio de parámetros que crece linealmente en $2p$, la probabilidad de que una inicialización aleatoria caiga en una región favorable no mejora solo por añadir capas, si esa inicialización sigue siendo aleatoria.

XY-QAOA Regularizado, en cambio, se mantiene en una banda mucho más estrecha y estable a lo largo de todo el rango de p (entre 16,50 % y 21,85 %), con desviación estándar consistentemente inferior a la de Standard QAOA en los ocho valores de p . Tampoco muestra una mejora monótona clara con p –el valor más bajo se alcanza en $p = 2$ y el más alto en $p = 3$ –, por lo que, dentro del rango estudiado ($p \in [1, 8]$), tampoco sigue la tendencia asintótica teórica; esto sugiere que, para $N = 14$, la calidad de la solución depende más de la inicialización TQA y del confinamiento del espacio de búsqueda que de la profundidad del circuito.

En `tiempo_vs_p`, el crecimiento es más suave que frente a N (Sección 6.4): con $N = 14$ fijo, el tiempo de ambos solvers crece de forma aproximadamente lineal con p (de $\sim 0,25$ – $0,44$ s en $p = 1$ a $\sim 4,8$ s en $p = 8$, un factor $\sim 11\times$ frente a un incremento $8\times$ en p), sin el patrón de recta logarítmica del escalado en N . Esto es coherente con el presupuesto de iteraciones de COBYLA (Ecuación (5.2)), que crece linealmente con p , y con que 2^N permanece fijo en esta fase: profundizar el circuito, a diferencia de escalar el universo de activos, tiene un coste computacional moderado y predecible.

Como control de coherencia interna, el punto $p = 3$ de esta sección –GAP de 35,69 % para Standard QAOA y 21,85 % para XY-QAOA Regularizado, con $N = 14$ – coincide exactamente con el punto $N = 14$ de la fase anterior. Esto confirma que ambas fases del experimento son consistentes entre sí y que no hay efectos espurios derivados de cómo se organizó el barrido (Sección 5.4.2).




Figura 6.6.: Reducción de Varianza Inter-Semilla del GAP de Optimización.

6.7. LIMITACIONES ESTADÍSTICAS

Cada punto de las figuras anteriores se apoya en $n = 12$ semillas por combinación de (Solver, N) o (Solver, p), con un único reinicio por semilla. Esta cifra es constante en todo el rango: el mecanismo de presupuesto de tiempo de la Sección 5.5 no llegó a activarse en la ejecución final (8038,3 s frente a un presupuesto de 4 horas), así que ningún N o p tiene menos muestras que otro por agotamiento del presupuesto. La limitación relevante no es, por tanto, una reducción progresiva del tamaño muestral con N , sino el tamaño moderado y uniforme de $n = 12$ en todos los puntos, combinado con el hecho de que el coste exponencial de la Sección 5.4.5 fue lo que impidió, dentro del alcance de este trabajo, ampliar ese número de semillas para las instancias con N mayor sin comprometer el resto del barrido.

Esta limitación no afecta por igual a todos los solvers: para Standard QAOA, la desviación estándar del Optimization GAP iguala o supera a la media en prácticamente todos los valores de N y p , así que su valor puntual debe

leerse como una estimación de tendencia central, no como una caracterización precisa de su comportamiento típico. XY-QAOA Regularizado, con desviaciones entre 3 y 5 veces menores en términos relativos, ofrece estimaciones puntuales más fiables con el mismo tamaño muestral, un efecto atribuible a la reducción del espacio de búsqueda efectivo (Sección 4.3.3) y a la menor sensibilidad de la inicialización TQA al punto de partida de cada semilla (Sección 4.4.1).

Esta limitación es consecuencia directa del coste computacional de la simulación por vector de estado (Sección 5.4.5), y no de un defecto oculto en el diseño experimental: el propio Capítulo 5 explica por qué $N = 20$ es el techo práctico del estudio y por qué el número de semillas se fijó en 12 para que el barrido cupiera en el presupuesto de tiempo disponible. Su consecuencia es que los valores puntuales de GAP y factibilidad en $N = 18-20$, en particular para Standard QAOA, deben leerse como estimaciones con un margen de incertidumbre considerable, más que como cifras exactas –algo que se retoma en el Capítulo 8 al valorar qué extensiones de presupuesto computacional o de acceso a hardware cuántico real permitirían estrechar estos intervalos.

7. VALORACIÓN ÉTICA

7.1. PRINCIPIOS DE LA ÉTICA

7.1.1. Honestidad y Rigor Científico

Uno de los pilares éticos de este trabajo es la honestidad intelectual y el rigor científico. En la literatura sobre tecnologías cuánticas aplicadas a los negocios es frecuente el *quantum hype*: prometer ventajas computacionales inmediatas que ignoran las limitaciones físicas del hardware actual.

Este proyecto evita esa deriva reportando de forma transparente las fronteras y restricciones del modelo. Como se analiza en el capítulo de resultados, el Optimization GAP repunta de forma sistemática al escalar el universo de activos hasta $N = 20$ cúbits con una profundidad de circuito fija. En lugar de ocultar este comportamiento eligiendo semillas favorables, se documenta que esa pérdida de precisión responde al límite de expresividad matemática del *ansatz*. Este rigor asegura que las conclusiones aporten valor científico real, sin distorsionar el estado del arte en finanzas cuantitativas.

7.1.2. Transparencia

Siguiendo el principio de verificabilidad de la ciencia, toda la arquitectura de software, los scripts, los archivos de configuración y los cuadernos de ejecución en la nube se han publicado en abierto en un repositorio público de GitHub: <https://github.com/Etxaaniiz/TFM2026>.

Esta decisión va más allá de la entrega académica: permite a cualquier investigador auditar el pipeline de datos, replicar las 40 instancias experimentales con los mismos parámetros y comprobar las ecuaciones de mapeo hacia el Hamiltoniano de Ising. Con ello se contribuye, en la medida de lo posible, a un desarrollo más abierto frente al secretismo habitual en el sector *Quantum Fintech*.

7.2. IMPACTO AMBIENTAL Y SOSTENIBILIDAD

7.2.1. Huella de Carbono de la Cuántica Clásica

La simulación exacta de vectores de estado (*statevector simulation*) tiene un coste energético que suele pasarse por alto. Por la naturaleza del espacio de Hilbert, la memoria RAM y el cómputo en CPU/GPU necesarios crecen de forma exponencial (2^N) con cada cúbit añadido al registro. Durante el desarrollo local y la ejecución del pipeline –optimizado con JAX y aceleración por GPU– las estaciones de trabajo operan a máxima potencia sostenida para procesar las transformaciones matriciales de gran escala ($N = 20$).

Esta demanda eléctrica se traduce en consumo real de los centros de datos que la sostienen. En este proyecto, compilar los algoritmos con Just-In-Time (JIT) ayuda a reducir ese consumo, acortando los tiempos de ejecución y el gasto en kilovatios-hora (kWh) frente a una simulación sin optimizar [17].

7.2.2. Eficiencia Energética

Frente al crecimiento exponencial e insostenible de la simulación clásica a gran escala, las Unidades de Procesamiento Cuántico (QPU) físicas de la era NISQ ofrecen un perfil energético muy distinto [7]: un procesador de compuertas superconductoras consume una potencia eléctrica prácticamente constante, sin depender de la complejidad combinatoria del problema. La mayor parte de esa energía se destina a la electrónica periférica y a la refrigeración criogénica que mantiene el chip cerca del cero absoluto ($T \approx 15$ mK) para limitar la decoherencia.

Comparando huellas: una vez que el tamaño del universo de activos supera el umbral en el que la simulación clásica deja de ser ventajosa, enviar el circuito XY-QAOA a una QPU real mediante APIs en la nube (como AWS Braket) implica una emisión de CO_2 muy inferior a la de un supercomputador (HPC) emulando el mismo entrelazamiento [17]. Por eso, la computación cuántica híbrida puede jugar un papel relevante en un sector financiero más sostenible (*Green Computing*) [17].

7.3. BRECHA TECNOLÓGICA CUÁNTICA

Integrar la mecánica cuántica en los modelos de asignación de capital plantea un dilema ético relacionado con la equidad de los mercados financieros internacionales. Desplegar algoritmos con preservación de simetría estructural como XY-QAOA exige infraestructuras de cómputo caras y personal muy especializado en física

cuántica y optimización matemática [18]. Hoy, estos recursos están concentrados casi en exclusiva en grandes bancos de inversión, fondos soberanos y laboratorios tecnológicos multinacionales.

Esta concentración de poder informático puede derivar en una brecha tecnológica estructural –el llamado *Quantum Divide* [19]–. Las organizaciones capaces de explotar en tiempo real soluciones óptimas bajo restricciones duras de cardinalidad exacta obtendrían ventajas de arbitraje frente a inversores minoristas o instituciones de economías emergentes sin acceso a la nube cuántica, lo que podría acentuar la desigualdad económica global y la concentración del capital. Publicar el código en abierto es la contribución de este proyecto para mitigar, en su pequeña medida, esa asimetría.

8. CONCLUSIONES Y TRABAJO FUTURO

8.1. CONCLUSIONES GENERALES

Este Trabajo de Fin de Máster ha abordado el problema de la selección de carteras financieras bajo restricciones discretas de cardinalidad mediante un algoritmo cuántico híbrido basado en QAOA, comparando su comportamiento frente a un solucionador exacto clásico (Gurobi) y frente a una metaheurística de referencia industrial (Recocido Simulado). El propósito del proyecto era responder a una pregunta concreta: *¿puede un ansatz variacional cuántico, diseñado para respetar restricciones combinatorias duras, resolver el problema de factibilidad del QAOA estándar sin sacrificar una calidad de solución razonable frente a los métodos clásicos establecidos?*

Los resultados del Capítulo 6 responden a esta pregunta de forma matizada. La sustitución de las penalizaciones QUBO blandas por el confinamiento geométrico del *XY-Mixer* sobre el estado de Dicke resuelve de forma estructural el problema de viabilidad: mientras que el QAOA estándar degrada su tasa de factibilidad hasta un 51–52 % en $N = 18$ –20, la arquitectura XY-QAOA mantiene una viabilidad matemática del 100 % en todas las instancias evaluadas, por construcción y no por ajuste estadístico (Sección 6.5). Es, con diferencia, la evidencia más sólida de todo el estudio.

En calidad de solución (Optimization GAP), el panorama cambia: bajo el régimen de un único reinicio evaluado en este trabajo, XY-QAOA Regularizado mejora de forma clara y consistente a Standard QAOA en los ocho valores de N estudiados, pero **no supera a Simulated Annealing**, que se mantiene en una meseta de 4–4,5 % frente al 11–22 % de XY-QAOA Regularizado (Sección 6.2). Esta diferencia es estadísticamente significativa en los ocho valores de N (test de Wilcoxon pareado por semilla, $p < 0,01$ en todos los casos), por lo que no se debe al azar de muestreo entre las 12 semillas evaluadas. En robustez financiera fuera de muestra, el Sharpe OOS de XY-QAOA Regularizado se sitúa entre el 76 % y el 95 % del valor de Gurobi OOS según N , sin diferencia estadísticamente significativa en ningún punto ($p > 0,05$ en los ocho valores de N); ambos enfoques son, por tanto, financieramente **comparables** fuera de muestra.

En conjunto, estas evidencias respaldan una tesis más acotada que la planteada inicialmente, pero más defendible: en el régimen NISQ actual, bajo simulación clásica exacta y con un presupuesto mínimo de reinicios, un algoritmo cuántico variacional bien diseñado **resuelve de forma determinista el problema de factibilidad** que aqueja al QAOA estándar, y alcanza una robustez financiera fuera de muestra **comparable** a la de un solucionador clásico exacto –pero no supera en calidad de solución (GAP) a una metaheurística clásica simple como

Simulated Annealing. El valor diferencial de este trabajo es, por tanto, la garantía estructural de factibilidad, no una ventaja de optimalidad ni de generalización financiera.

8.2. GRADO DE CUMPLIMIENTO DE LOS OBJETIVOS E HIPÓTESIS

Contrastando los resultados del Capítulo 6 con los objetivos específicos de la Sección 2.1.2: OE1 (equivalencia QUBO–Ising) queda validado por la verificación de la Sección 5.6, con coincidencia exacta en el 100 % de las 15 combinaciones evaluadas. OE2 (factibilidad estructural) se cumple con holgura: 100 % de viabilidad en todo el rango $N = 6$ a $N = 20$, frente a la degradación progresiva de Standard QAOA (Sección 6.5).

OE3 (efecto estabilizador de TQA y Ridge L_2) se cumple solo **parcialmente**. Aislando el efecto puro de TQA –comparando XY-QAOA con inicialización aleatoria frente a XY-QAOA Regularizado, ambos con el mismo mezclador XY – el test de Wilcoxon pareado no encuentra diferencia significativa en el GAP medio en ninguno de los ocho valores de N (p entre 0,07 y 0,90), y la reducción de varianza atribuible a TQA es inconsistente entre valores de N (entre $-11,2\%$ y $+34,1\%$, media $6,4\%$). La regularización Ridge L_2 no aporta mejora aislada alguna (Sección 8.3). El objetivo se cumple en el sentido de que se ha evaluado rigurosamente el efecto de ambos mecanismos, pero la evidencia no respalda que ninguno de los dos estabilice, por sí solo, el bucle variacional de forma estadísticamente significativa en el rango estudiado.

OE4 (contraste frente a solucionadores clásicos) se cumple en el sentido de que se ha hecho la comparación sistemática solicitada, con un resultado claro aunque no el anticipado: XY-QAOA Regularizado no iguala a Simulated Annealing en GAP (diferencia significativa, $p < 0,01$ en los ocho valores de N), pero sí resulta financieramente comparable a Gurobi en Sharpe OOS (diferencia no significativa, $p > 0,05$ en los ocho valores de N), y el umbral a partir del cual la simulación clásica deja de ser práctica se sitúa entre $N = 14$ y $N = 16$ (Sección 6.4).

En conjunto, se considera cumplido el objetivo general en su vertiente de diseño, implementación y evaluación sistemática del algoritmo propuesto. El grado de competitividad frente a los métodos clásicos debe matizarse: completo en factibilidad, comparable en robustez financiera fuera de muestra, y no alcanzado en calidad de solución frente a una metaheurística clásica simple bajo este diseño experimental concreto.

8.2.1. Contraste de las Hipótesis de Trabajo

La Tabla 8.2.1 resume el grado de confirmación de las hipótesis de la Sección 2.1.3, a la luz de la evidencia estadística del Capítulo 6.

Hipótesis	Evidencia	Resultado
H1: el XY-Mixer mejora la factibilidad	100 % de factibilidad en XY-QAOA/XY-QAOA Reg. en todo el rango, frente a una caída de Standard QAOA hasta $\sim 52\%$ en $N = 18-20$ (Sección 6.5)	Confirmada
H2: TQA estabiliza la optimización	Aislado el efecto de TQA frente a inicialización aleatoria (mismo mezclador XY), sin diferencia significativa en el GAP medio ($p > 0,07$ en los 8 valores de N) ni reducción consistente de varianza	No confirmada con la evidencia disponible
H3: Ridge L_2 aporta mejora adicional	La ablación de α no muestra mejora consistente; el término queda desactivado en la configuración final (Sección 8.3)	No confirmada
H4: competitividad frente a clásicos	GAP significativamente peor que Simulated Annealing ($p < 0,01$ en los 8 valores de N); Sharpe OOS sin diferencia significativa frente a Gurobi ($p > 0,05$)	Parcialmente confirmada (competitivo en Sharpe, no en GAP)
H5: límite de expresividad a p fijo	Repunte del GAP en $N = 18-20$; el escalado en p (Sección 6.6) sugiere margen de mejora al aumentar la profundidad	Confirmada

8.3. LIMITACIONES DEL TRABAJO

A pesar de los resultados obtenidos, conviene reconocer las limitaciones del estudio:

- **Simulación sin ruido físico.** Todos los experimentos se ejecutaron mediante simulación exacta de vector de estado (*statevector*), sin modelar canales de ruido de hardware real. Los resultados de viabilidad y GAP representan, por tanto, una cota superior de rendimiento frente a un procesador cuántico físico actual.
- **XY-QAOA Regularizado no supera a Simulated Annealing en calidad de solución.** Bajo el diseño experimental de este trabajo (un único reinicio, simulación exacta), el GAP medio del enfoque cuántico es significativamente peor que el de una metaheurística clásica simple en todo el rango de N . Esta limitación es central para interpretar el alcance de la contribución: el valor demostrado reside en la garantía estructural de factibilidad, no en una ventaja de optimalidad.
- **Contribución de TQA y de la regularización Ridge L_2 no confirmada estadísticamente.** Como se detalla en la Sección 8.2, ni la inicialización TQA ni la penalización Ridge L_2 muestran, por sí solas, una mejora estadísticamente significativa sobre el GAP medio o su variabilidad en el rango de N estudiado.
- **Límite de expresividad a profundidad fija.** El repunte del GAP en $N = 18-20$ confirma que, para una profundidad de circuito p fija, el ansatz agota su capacidad de representación al crecer N .

- **Coste computacional de la simulación clásica.** El tiempo de ejecución escala mucho peor que los solucionadores clásicos de referencia, limitando la escala de universos de activos evaluables y alejando, por ahora, la viabilidad de un despliegue en tiempo real.
- **Alcance del modelo financiero.** El estudio se restringe a un modelo estático de media-varianza de un único periodo sobre renta variable (S&P 500 / IBEX), sin costes de transacción ni rebalanceo dinámico.
- **Tamaño muestral moderado.** Cada punto se apoya en $n = 12$ semillas, lo que produce intervalos de confianza relativamente amplios, en particular para Standard QAOA en N elevado (Sección 6.7).

8.4. LÍNEAS FUTURAS DE TRABAJO

A partir de las limitaciones anteriores, se identifican las siguientes líneas de continuación, de menor a mayor alcance:

1. **Validación en hardware cuántico real.** Ejecutar el circuito XY-QAOA en plataformas NISQ físicas para contrastar la degradación de viabilidad y GAP frente a la simulación exacta.
2. **Ampliación del número de reinicios y de semillas.** Dado que Standard QAOA y, en menor medida, XY-QAOA Regularizado muestran varianza inter-semilla elevada con un único reinicio, evaluar si un presupuesto de reinicios mayor (más realista en emuladores clásicos que en hardware NISQ) reduce la brecha de GAP frente a Simulated Annealing.
3. **Búsqueda de hiperparámetros más amplia para TQA y Ridge.** Como no se ha confirmado estadísticamente una mejora de estos mecanismos en el rango estudiado, explorar con optimización bayesiana la rampa temporal de TQA y el coeficiente α de Ridge, para ver si existe una región del espacio de hiperparámetros donde sí aporten una mejora consistente.
4. **Estrategias de profundidad adaptativa.** Investigar esquemas de *warm-start* o de crecimiento incremental de p (p. ej. ADAPT-QAOA) para compensar el límite de expresividad detectado.
5. **Extensión del modelo financiero.** Incorporar rebalanceo dinámico multiperiodo, costes de transacción y restricciones sectoriales o de liquidez.
6. **Ampliación del universo de activos y regímenes de mercado.** Evaluar el algoritmo sobre otras clases de activos y bajo distintos regímenes de mercado.

7. **Exploración de arquitecturas alternativas.** Comparar el XY-Mixer con otros esquemas de preservación de restricciones (p. ej. *Grover-mixer*, QAOA+ multiángulo) que puedan cerrar la brecha de GAP frente a Simulated Annealing.
8. **Análisis de coste energético a escala.** Extender el análisis de huella de carbono a escenarios de despliegue en QPU real.

En definitiva, este trabajo demuestra que la preservación estructural de restricciones mediante circuitos cuánticos especializados resuelve de forma robusta y verificable el problema de factibilidad del QAOA estándar, y ofrece una robustez financiera fuera de muestra comparable a la de un solucionador clásico exacto. Cerrar la brecha de calidad de solución frente a metaheurísticas clásicas simples queda como el reto más relevante para que el enfoque sea competitivo en optimalidad, y no solo en factibilidad, en próximas iteraciones de este trabajo.

BIBLIOGRAFÍA

- [1] H. Markowitz, "Portfolio selection," *The Journal of Finance*, 1952. [Online]. Available: <https://www.jstor.org/stable/2975974>
- [2] D. J. Egger, C. Gambella, J. Marecek, S. McFaddin, M. Mevissen, R. Raymond, A. Simonetto, S. Woerner, and E. Yndurain, "Quantum computing for finance: State-of-the-art and future prospects," *IEEE Transactions on Quantum Engineering*, 2020. [Online]. Available: <https://ieeexplore.ieee.org/document/9143004>
- [3] P. Rebentrost, B. Gupt, and T. R. Bromley, "Quantum computational finance: Monte carlo pricing of financial derivatives," *Physical Review A*, 2018. [Online]. Available: <https://journals.aps.org/pr/abstract/10.1103/PhysRevA.98.022321>
- [4] CaixaBank, "Caixabank realiza los primeros proyectos de i+d de españa para aplicar la computación cuántica a la actividad financiera," CaixaBank Newsroom, 2019. [Online]. Available: <https://www.caixabank.com/es/actualidad/noticias/primeros-proyectos-computacion-cuantica.html>
- [5] BBVA, "Bbva pursues the financial sector's 'quantum advantage'," BBVA Innovation, 2020. [Online]. Available: <https://www.bbva.com/en/innovation/bbva-pursues-the-financial-sectors-quantum-advantage/>
- [6] S. Mugel, C. Kuchkovsky, E. Sanchez, S. Fernandez-Lorenzo, J. Luis-Pueyo, R. Lizaso, and R. Orus, "Dynamic portfolio optimization with real datasets using quantum processors and quantum-inspired annealers," *Science China Information Sciences*, 2022. [Online]. Available: <https://link.springer.com/article/10.1007/s11432-021-3342-x>
- [7] J. Preskill, "Quantum computing in the NISQ era and beyond," *Quantum*, 2018. [Online]. Available: <https://doi.org/10.22331/q-2018-08-06-79>
- [8] E. Farhi, J. Goldstone, and S. Gutmann, "A quantum approximate optimization algorithm," *arXiv preprint arXiv:1411.4028*, 2014. [Online]. Available: <https://arxiv.org/abs/1411.4028>
- [9] (2025) Gurobi optimizer reference manual | gurobi optimization. [Online]. Available: <https://www.gurobi.com>
- [10] J. R. McClean, S. Boixo, V. N. Smelyanskiy, R. Babbush, and H. Neven, "Barren plateaus in quantum neural network training landscapes," *Nature Communications*, 2018. [Online]. Available: <https://www.nature>

[com/articles/s41467-018-07090-4](https://arxiv.org/abs/2305.03857)

- [11] Z. He, R. Shaydulin, S. Chakrabarti, D. Herman, C. Li, Y. Sun, and M. Pistoia, "Alignment between initial state and mixer improves QAOA performance for constrained optimization," 2023. [Online]. Available: <https://arxiv.org/abs/2305.03857>
- [12] P. Niroula, R. Shaydulin, R. Yalovetzky, P. Minssen, D. Herman, S. Hu, and M. Pistoia, "Constrained quantum optimization for extractive summarization on a trapped-ion quantum computer," 2022.
- [13] S. Brandhofer, D. Braun, V. Dehn, G. Hellstern, M. Hüls, Y. Ji, I. Polian, A. S. Bhatia, and T. Wellens, "Benchmarking the performance of portfolio optimization with QAOA."
- [14] J. Mancilla, T. D. Bouloumis, and F. Goguikian, "Constrained portfolio optimization via quantum approximate optimization algorithm (qaoa) with xy-mixers and trotterized initialization," *arXiv preprint arXiv:2602.14827*, 2026. [Online]. Available: <https://arxiv.org/abs/2602.14827>
- [15] S. H. Sack and M. Serbyn, "Quantum annealing initialization of the quantum approximate optimization algorithm," 2021.
- [16] P. K. Barkoutsos, G. Nannicini, A. Robert, I. Tavernelli, and S. Woerner, "Improving variational quantum optimization using CVaR," *Quantum*, 2020. [Online]. Available: <https://quantum-journal.org/papers/q-2020-04-20-256/>
- [17] C. Berger, T. Challawala, D. Jaschke, and S. Montangero, "Quantum computing vs. HPC: A comprehensive energy efficiency and carbon footprint analysis," *IEEE Transactions on Green Communications and Networking*, 2023. [Online]. Available: <https://ieeexplore.ieee.org/>
- [18] Project Management Institute, *A Guide to the Project Management Body of Knowledge (PMBOK Guide)*. Project Management Institute, 2021. [Online]. Available: <https://www.pmi.org/pmbok-guide-standards>
- [19] T. S. Humble, K. M. Svore, and T. Hoefler, "Socioeconomic implications and the technological gap in early quantum computing adoption," *IEEE Technology and Society Magazine*, 2022. [Online]. Available: <https://ieeexplore.ieee.org/document/9863768>

A. DECLARACIÓN DE USO DE INTELIGENCIA ARTIFICIAL

De acuerdo con las directrices de transparencia recogidas en la actualización de marzo de 2025 del *IEEE Editorial Style Manual* sobre el uso de contenido generado por IA en documentos académicos, se detalla a continuación el nivel de integración y las herramientas empleadas durante el desarrollo de este Trabajo de Fin de Máster. Se declara el uso de un modelo de lenguaje LLM (Claude) como asistente de investigación, con el objetivo de mejorar la productividad en la maquetación, depuración del documento y desarrollo de código. Su uso se ha limitado a los siguientes ámbitos:

- **Asistencia en el desarrollo de código:** En los Capítulos 5 y 6, el asistente actuó como apoyo técnico durante la implementación — ayudando a depurar, estructurar y documentar el código cuántico — siempre bajo las directrices y especificaciones técnicas del autor.
- **Estructuración y formateo en LaTeX:** El asistente se utilizó para generar entornos LaTeX, incluyendo la sintaxis de tablas, la gestión de referencias cruzadas y la configuración de la jerarquía de capítulos, asegurando el cumplimiento de los estándares tipográficos requeridos.
- **Revisión ortotipográfica y mejora gramatical:** Se empleó a lo largo del documento para refinar el estilo lexico, garantizar la coherencia terminológica y corregir errores gramaticales, práctica expresamente reconocida en las políticas del IEEE.